Trabajo Fin de Grado – Curso 2024/2025

Modelización y ajuste de datos reales mediante modelos compartimentales.

Autorr: José Ramón Mena Pérez

Tutor: Gladston Duarte

Facultat de Ciències Matemàtiques

Grado en Matemáticas

Agradecimientos

Quiero agradecer a todos y a cada uno de mis amigos y compañeros que alguna vez me ayudaron, me prestaron unos apuntes o que simplemente me sacaron una sonrisa en un mal día.

Dar las gracias infinitas a mis dos grandes grupos de amigos los cuales siempre estuvieron ahí para mí, ayúdandome siempre en lo que necesitara, daba igual la hora o el momento. Por supuesto a mi tutor, quien a pesar de múltiples dificultades me ha dado una oportunidad.

Quiero hacer mención especial a dos personas de estos grupos que son Axel y Alberto, personas increíbles y sin las cuales no habría disfrutado la carrera como la he disfrutado.

No olvidarme de mis padres, que nunca se separaron de mí y que a pesar de no estar tan al tanto como en períodos estudiantiles previos siempre tenían una palabra de ánimo y fuerza para darme.

Dar las gracias también a mi novia, una persona inigualable que me acompañó en cada momento de la carrera y especialmente en los más difíciles, lo cual hace que mi gratitud sea aún más eterna.

El premio especial y mi mayor agradecimientose se lo lleva mi mejor y más querido amigo Pau Part, quien desde el primer día estuvo ahí conmigo para no separarse jamás de mí, la persona que me ha llevado en volandas en esta etapa, una persona en la cual siempre pude confiar y en la que confiaré para siempre. Gracias de corazón.

Índice general

1. Introducción **2**
1.1. El problema de la criminalidad 2
1.2. Resumen de la metodología 3
1.3. Objetivo del TFG 4

2. EDOs y Modelo SIR **6**
2.1. EDOs lineales homogéneas 6
2.2. Modelo SIR 8
2.2.1. Ejemplos ilustrativos del modelo 11

3. Modelización de la incidencia delictiva **23**
3.1. Explicación del Modelo 23
3.1.1. Justificación de la positividad del modelo 26
3.2. Dinámica del Modelo 26
3.2.1. Número Básico de Reproducción R_0 27
3.3. Calibración de los Parámetros 29
3.3.1. Crimen en España Período 2009-2019 30
3.4. Capacidad Predictiva del Modelo 33
3.4.1. Período 2009-2012 34
3.4.2. Período 2009-2016 35
3.5. Análisis de Sensibilidad 36

4. Conclusiones **40**
4.1. Resumen y Análisis del Desarrallo del TFG 40
4.2. Conclusiones Finales 41

Bibliografía **41**

Apéndice **43**

Capítulo 1

Introducción

1.1. El problema de la criminalidad

El crimen, entendido aquí como conductas delictivas que se "propagan" por influencia social, constituye un reto de primer orden en nuestras sociedades contemporáneas. Sus consecuencias son devastadoras tanto a nivel individual como colectivo. Víctimas y agresores, sufren secuelas físicas y psicológicas a través de la inseguridad ciudadana, la desconfianza mutua entre vecinos y la pérdida de cohesión social. Desde la perspectiva de la salud pública, la violencia y la victimización derivadas del crimen se asocian a un incremento significativo de trastornos mentales como ansiedad, depresión y estrés postraumático, así como al agravamiento de dolencias crónicas preexistentes debido al estrés. Este fenómeno se traduce en un consumo elevado de recursos sanitarios y de emergencia, que incluyen atención hospitalaria, intervenciones de salud mental y programas de rehabilitación psicosocial, aumentando la presión sobre los sistemas sanitarios y sociales.

A nivel económico, el crimen genera un coste muy elevado que abarca múltiples frentes: gastos en intervención policial, procesos judiciales, mantenimiento de infraestructuras penitenciarias, indemnizaciones a víctimas, programas de reinserción social y laboral, además de pérdidas directas por robos, daños materiales o vandalismo. Asimismo, existen repercusiones indirectas que impactan negativamente en la actividad económica local y nacional: descenso de la inversión y de la actividad comercial en zonas de alta criminalidad, caída del turismo en regiones consideradas inseguras, incremento de las primas en seguros y, en general, una sensación de inestabilidad que retrasa proyectos de desarrollo urbano y social.

El crimen es un fenómeno complejo que impacta a millones de personas en todo el mundo. Diversos factores pueden incrementar el riesgo de que un individuo se involucre en actividades delictivas, incluidos aspectos genéticos, biológicos, psicológicos y sociales. Estudios de criminología apuntan a que ciertos rasgos temperamentales o predisposiciones biológicas (como impulsividad elevada por ejemplo) pueden facilitar la conducta agresiva, mientras que factores psicológicos como estrés crónico, trastornos de personalidad, baja autoestima; y sociales como entornos de desigualdad, débiles lazos comunitarios, fácil acceso a redes delictivas actúan como catalizadores

[1]. Asimismo, la exposición continuada a la violencia en el hogar o en el barrio incrementa la probabilidad de "aprender" comportamientos delictivos como una vía de resolución de conflictos o de obtención de recursos [2].

A pesar de la magnitud del problema, el crimen sigue estando estigmatizado de formas que dificultan su abordaje efectivo. Muchas comunidades evitan reconocer la incidencia real de violencia o delitos por temor a dañar su reputación o a sufrir represalias, lo que impide que las víctimas denuncien y buscan ayuda. Además, existen barreras de acceso a intervenciones de reinserción y apoyo psicológico debido a recursos económicos limitados, falta de programas de mediación comunitaria y escasa conciencia sobre las causas estructurales del fenómeno. Estas dificultades perpetúan ciclos de violencia y exclusión.

El "tratamiento" del crimen exige un enfoque multidisciplinar. Deben tomarse medidas policiales, producirse intervenciones judiciales, promulgar programas de rehabilitación social y brindar apoyo psicológico tanto a víctimas como a agresores. Esto puede incluir vigilancia focalizada en zonas de alta incidencia, mediación entre pandillas, talleres de habilidades sociales, terapia cognitivo-conductual para agresores, formación laboral y acompañamiento a la reinserción. La prevención también juega un papel esencial e implica campañas de sensibilización, políticas de desarrollo urbano inclusivo, fortalecimiento de redes de apoyo vecinal y fomento de alternativas de ocio y empleo para jóvenes en riesgo.

El crimen continúa siendo un desafío de salud pública y cohesión social, con efectos profundos en el bienestar de las personas y de las comunidades. Para enfrentarlo con eficacia, es imprescindible adoptar una perspectiva integral que combine prevención, detección temprana y estrategias de intervención equilibradas. Del mismo modo, resulta esencial reducir el estigma asociado a la violencia, mejorar el acceso a servicios de apoyo y abordar las causas subyacentes como desigualdad, exclusión y falta de oportunidades.

1.2. Resumen de la metodología

En este trabajo trataremos el crimen como un proceso transmisible socialmente, planteándolo como una "epidemia" cuyos "portadores" son individuos que, a través de relaciones y redes sociales, pueden "infectar" a susceptibles con conductas delictivas. Propondremos un modelo compartimental basado en la estructura SIR clásica —Susceptibles (S), Criminales activos (I) y Ciudadanos "recuperados" o alejados de la delincuencia (R)—para estudiar la evolución de las conductas delictivas en un entorno urbano, explicaremos en un capítulo concreto el Modelo Básico y que papel juegan las ecuaciones diferenciales en este. Este enfoque permite no solo cuantificar la incidencia delictiva a lo largo del tiempo, sino también simular escenarios de intervención y medir su impacto potencial antes de su implementación real.

Los modelos compartimentales, ampliamente conocidos y utilizados en epide-

miología para estudiar la transmisión de enfermedades infecciosas, ofrecen un marco conceptual y matemático muy valioso para capturar la dinámica de difusión de comportamientos sociales. Estos modelos dividen a los individuos en grupos homogéneos —o compartimentos— y describen las tasas de paso entre ellos mediante ecuaciones diferenciales ordinarias. Con esta metodología es posible analizar cómo un "contagio" conductual, como el crimen, se extiende de unos grupos a otros, así como evaluar la eficacia de diferentes estrategias de intervención como campañas de prevención, programas de reinserción de exdelincuentes, patrullajes focalizados, políticas de control comunitario, entre otras. Aunque su origen se sitúa en el estudio de brotes infecciosos como la gripe, el VIH o el COVID-19, su aplicabilidad se extiende a cualquier fenómeno que se transmita por contacto o influencia social, como comportamientos de riesgo, adicciones o, en nuestro caso, actividades delictivas.

1.3. Objetivo del TFG

El objetivo principal de este TFG es aplicar una variación del modelo SIR al estudio del crimen, formulando un sistema de ecuaciones diferenciales no lineales que describa con rigor la dinámica de la incidencia delictiva. Para ello, en el Capítulo 2 realizaremos una revisión exhaustiva de las ecuaciones diferenciales ordinarias lineales homogéneas y de su aplicación a dinámicas poblacionales, estableciendo las bases matemáticas necesarias. En el mismo capítulo presentaremos en detalle el modelo de Kermack–McKendrick como punto de partida, aportando ejemplos ilustrativos para su mejor comprensión. A continuación extenderemos su formulación para definir un sistema compartimental adaptado al contexto delictivo en el Capítulo 3, incorporando términos que representen tanto la "transmisión" del comportamiento criminal como la "recuperación" o alejamiento de la actividad delictiva.

Nos centraremos en la estimación de los parámetros del modelo a partir de datos reales de criminalidad, empleando técnicas de ajuste por mínimos cuadrados y optimización numérica. Evaluaremos el rendimiento del modelo calculando el error cuadrático medio y comparándolo con series históricas para validar su capacidad predictiva. Finalmente realizaremos un análisis de sensibilidad a partir de los valores y parámetros presentes en el Número Básico de Reproducción R_0, con el fin de identificar el parámetro o conjunto de parámetros más influyentes en la propagación del crimen y, por ende, determinar qué estrategias de control serían potencialmente más eficaces.

En resumen, este TFG persigue adaptar un modelo compartimental tipo SIR al fenómeno delictivo para comprender con mayor profundidad su evolución y ofrecer un marco cuantitativo que sirva de apoyo a la toma de decisiones en materia de prevención y control del crimen.

Capítulo 2

EDOs y Modelo SIR

En este capítulo del trabajo veremos como se aplicam las ecuaciones diferenciales a dinámicas poblacionales o dinámicas epidemiológicas, lo cual será fundamental para entender el comportamiento del modelo SIR y su desarrollo, el cual también veremos de manera ejemplificada. Todo ello como premisa a la variante que aplicaremos para nuestros datos del crimen.

2.1. EDOs lineales homogéneas

Supongamos una población ubicada en una región determinada. Durante un año, una fracción α de la población nace, una fracción β fallece, y además se producen entradas y salidas de individuos debido a movimientos migratorios. Sea $x(t)$ el número de habitantes en el año t. Entonces, el modelo discreto básico se escribe como:

$$x(t+1) = x(t) + \alpha\, x(t) - \beta\, x(t) - e(t) + i(t). \tag{2.1}$$

donde $e(t)$ e $i(t)$ representan el número de emigrantes e inmigrantes durante el año t, respectivamente.

Para una mejor aproximación, podemos dividir el intervalo de tiempo. Por ejemplo, si consideramos medio año tendremos la siguiente ecuación:

$$x\big(t+\tfrac{1}{2}\big) = x(t) + \tfrac{1}{2}\,\alpha\, x(t) - \tfrac{1}{2}\,\beta\, x(t) - \tfrac{1}{2}\, e(t) + \tfrac{1}{2}\, i(t). \tag{2.2}$$

Para ello se supone lo siguiente:

- En medio año nacerá la mitad de las personas que nacerían en un año:

$$\tfrac{1}{2}\,\alpha\, x(t).$$

- Morirá la mitad de las que morirían en un año:

$$\tfrac{1}{2}\,\beta\,x(t).$$

- Emigrarán la mitad de los emigrantes anuales:

$$\tfrac{1}{2}\,e(t).$$

- Entrarán la mitad de los inmigrantes anuales:

$$\tfrac{1}{2}\,i(t).$$

De ahí la ecuación (2.2)

Por otro lado hablemos de los paráemtros α y β que corresponden como bien hemos mencionado anteriormente a las tasas de natalidad y mortalidad anual respectivamente. Su definición en este contexto es la siguiente:

$$\alpha(\text{Tasa de Natalidad}) = \frac{\text{nacidos}}{\text{población} \times \text{tiempo}}.$$

$$\beta(\text{Tasa de Mortalidad}) = \frac{\text{fallecidos}}{\text{población} \times \text{tiempo}}.$$

Finalmente, si nos acercamos a un modelo continuo y tomamos un intervalo lo más pequeño posible Δt, obtenemos:

$$x(t+\Delta t) = x(t) + \Delta t\,\alpha\,x(t) - \Delta t\,\beta\,x(t) - \Delta t\,e(t) + \Delta t\,i(t). \tag{2.3}$$

de donde despejando cuidadosamente y tomando el límite cuando $\Delta t \to 0$ se obtiene la siguiente EDO lineal:

$$\lim_{\Delta t \to 0} \frac{x(t+\Delta t) - x(t)}{\Delta t} = x'(t) = \mu\,x(t) + \gamma(t). \tag{2.4}$$

con $\mu = \alpha - \beta$ y $\gamma(t) = i(t) - e(t)$.

Esta ecuación representa la tasa de variación instantánea de la población, es decir, describe la velocidad con la que crece la población en el tiempo.

En el caso de que $\gamma(t) = 0$ en (2.4) tenemos un sistema cerrado en el que no hay ni emigración ni tampoco inmigración. Este sería el modelo más simple propuesto por Thomas Robert Malthus sobre el crecimiento exponencial de la poblacións, el cual viene dado por la siguiente ecuación diferencial:

$$x'(t) = \mu\, x(t). \tag{2.5}$$

2.2. Modelo SIR

El modelo SIR propuesto por Kermack y McKendrick para el estudio del crecimiento poblacional divide la población en tres compartimentos homogéneos, asumiendo que todos los individuos de un mismo grupo comparten características epidemiológicas similares.

En primer lugar, $S(t)$ representa el número de individuos $Susceptibles$, es decir, aquellos que en el instante t todavía no están infectados pero pueden contraer la enfermedad si entran en contacto con portadores.

A continuación, $I(t)$ denota la población $Infectada$, compuesta por individuos que ya han contraído el patógeno, lo están propagando activamente y pueden transmitirlo a los susceptibles.

Finalmente, $R(t)$ recoge a los *Recuperados* o *Eliminados*: personas que han superado la fase contagiosa (por recuperación o por muerte) y ya no participan en la dinámica de transmisión.

La única variable independiente del modelo es el tiempo continuo t. Para describir cómo se desplaza la población de un compartimento a otro, se utilizan ecuaciones diferenciales ordinarias que relacionan las derivadas $\frac{dS}{dt}$, $\frac{dI}{dt}$ y $\frac{dR}{dt}$ con las tasas de contagio y recuperación.

El proceso de contagio se modela suponiendo que las nuevas infecciones ocurren a un ritmo proporcional al producto $S(t)I(t)$, escalado por un coeficiente β que mide la eficacia de la transmisión. Por su parte, las recuperaciones (o eliminaciones) suceden a una velocidad proporcional al número de infectados, con una tasa α que refleja el periodo medio de enfermedad.

Al expresar estas relaciones, obtenemos el sistema:

$$\begin{aligned} S'(t) &= -\beta\, S(t)\, I(t), \\ I'(t) &= \beta\, S(t)\, I(t) \;-\; \alpha\, I(t), \\ R'(t) &= \alpha\, I(t). \end{aligned} \tag{2.6}$$

¿De dónde salen estas ecuaciones (2.6)?

En primer lugar la ecuación $S'(t) = -\beta\, S(t)\, I(t)$ representa la disminución de susceptibles, como pasan de $S(t)$ a $I(t)$, en este caso los individuos se infectan a ritmo proporcional a $\beta\, S\, I$ como bien hemos mencionado anteriormente, donde β es la tasa de transmisión, es decir, el número de contagio por unidad de tiempo y por parejas de susceptible-infectado.

Está expresión tiene un sentido probabilístico tanto desde el punto de vista del infectado como del susceptible. La probabilidad de que un infectado contacte con un susceptible es $\frac{S}{N}$, por lo que el número de nuevas infecciones por unidad de tiempo y por infectado es $(\beta N)\,\frac{S}{N}$, dando una tasa total $(\beta N)\,\frac{S}{N}\, I = \beta\, S\, I$. De la misma manera, la probabilidad de que un susceptible contacte un infectivo es $\frac{I}{N}$, con lo que las infecciones por unidad de tiempo y por susceptible son $(\beta N)\,\frac{I}{N}$, resultando en $(\beta N)\,\frac{I}{N}\, S = \beta\, S\, I$, obsérvese que ambos enfoques proporcionan la misma tasa de nuevas infecciones.

En el caso de la segunda ecuación del sistema $I'(t) = \beta\, S(t)\, I(t) - \alpha\, I(t)$ tenemos la variación o evolución de los infectados. Por un lado tenemos el factor $\beta\, S(t)\, I(t)$, que como hemos visto antes son los susceptibles que pasan a estado infectivo y por otro lado tenemos la segunda parte de la ecuación donde aparece el factor $\alpha I(t)$, que es la tasa con la que los infectados abandonan dicha clase por unidad de tiempo.

Esta es otra de las hipótesis del modelo SIR, la cual requiere una explicación matemática más completa, ya que la suposición de que la tasa de recuperación sea proporcional al número de infectivos no tiene un significado epidemiológico claro.

Consideramos la conjunto de miembros que fueron todos infectados al mismo tiempo y dejamos que $u(s)$ denote el número de estos que aún están infectivos s unidades de tiempo después de haber sido infectados. Si una fracción α de estos deja la clase de infectivos en una unidad de tiempo, entonces

$$u' = -\alpha u.$$

y la solución de esta ecuación diferencial elemental es

$$u(s) = u(0)e^{-\alpha s}.$$

Así, la fracción de infectivos que permanecen infectivos s unidades de tiempo después de haber sido infectados es $e^{-\alpha s}$, de modo que la duración del período infectivo se distribuye exponencialmente con media

$$\int_0^\infty e^{-\alpha s}\, ds = \frac{1}{\alpha},$$

y esto es lo que realmente asumimos en nuestro modelo.

Finalmente, la tercera ecuación indica cómo crece el compartimento de recuperados/eliminados $R(t)$ a partir de los infectados que se recuperan o mueren por unidad de tiempo.

Veánse las siguientes tablas resumen:

Parámetro	Significado
β	Tasa de transmisión: número de nuevos contagios por unidad de tiempo y por pareja susceptible–infectado.
α	Tasa de recuperación (o eliminación): proporción de infectados que dejan de ser contagiosos por unidad de tiempo.

Cuadro 2.1: Descripción de los parámetros del modelo SIR.

Ecuación	Significado
$S'(t) = -\beta\, S(t)\, I(t)$	Disminución de susceptibles: los individuos se infectan a ritmo proporcional a $\beta\, S\, I$.
$I'(t) = \beta\, S(t)\, I(t) - \alpha\, I(t)$	Variación de infectados: ganancia por nuevos contagios menos pérdida por recuperaciones.
$R'(t) = \alpha\, I(t)$	Incremento de recuperados/eliminados: los infectados dejan de ser contagiosos a razón de $\alpha\, I$.

Cuadro 2.2: Interpretación de las ecuaciones del modelo SIR.

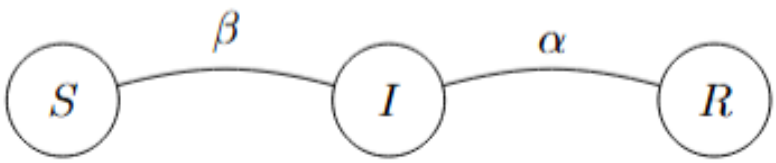

Figura 2.1: Diagrama modelo SIR

Otras hipótesis del modelo SIR

- **Población constante.** La población es fija, no se consideran nacimientos ni muertes ajenas a la enfermedad durante el período de estudio. Si N es el tamaño total de la población.

$$N = S(t) + I(t) + R(t). \tag{2.7}$$

- **Transmisión por contacto directo.** La infección solo se adquiere mediante el encuentro entre un individuo susceptible y otro infectado.

- **Ingreso inmediato en infectados.** Tan pronto como un susceptible adquiere la enfermedad, pasa directamente al compartimento $I(t)$.

- **Salida de infectados.** Los individuos en $I(t)$ abandonan este grupo al recuperarse o fallecer, incorporándose al compartimento $R(t)$.

2.2.1. Ejemplos ilustrativos del modelo

En este apartado mostraremos un par de ejemplos ilustrativos del modelo SIR. Usaremos los datos que nos proporcionan distintas fuentes acerca de dos epidemias ocurridas en el pasado para calibrar los parámetros α y β de nuestro modelo. Para cada uno de ellos usaremos un método distintos. Por un lado usaremos el ajuste por mínimos cuadrados y por otro un resultado teórico proporcionado por [5] que relaciona ambos parámetros a través de los datos.

Brote de Gripe en Inglaterra

En 1978, la revista *British Medical Journal* [6] publicó un estudio sobre un brote de gripe en un internado del norte de Inglaterra. Dicho brote se extendió desde el 22 de enero hasta el 4 de febrero, llegando a afectar a 512 de las 763 personas que habitaban el internado, teniendo constancia que la epidemia empezó con un único caso inicial. La Tabla 2.3 muestra el número de individuos enfermos registrados cada día.

Día	1	2	3	4	5	6	7	8	9	10	11	12	13	14
Infectados reales	3	8	28	75	221	291	255	235	190	125	70	28	12	5

Cuadro 2.3: Número real de individuos infectados en 1978.

En este escenario, la población total permanece constante, lo que resulta adecuado para aplicar el modelo SIR. Para calibrar los parámetros de nuestro modelo como bien mencionamos al inicio de la sección usaremos el ajuste por mínimos cuadrados que busca encontrar los valores de los parámetros α y β a través de la minimización de la siguiente expresión.

$$\min_{\beta,\alpha} \sum_{t=0}^{T} \big(I(t) - d(t+1)\big)^2.$$

donde $d(t)$ es el vector de infectados reales.

Para ello usaremos la herramiento computacional de *Wolfram Mathematica* a través del código 4.2, cuyo pseudocódigo es el siguiente:

Algorithm 1 Ajuste de parámetros para modelo SIR

1: Definir el modelo SIR como sistema de EDOs:
   $s'(t) = -\beta s(t)i(t)$.
   $i'(t) = \beta s(t)i(t) - \alpha i(t)$.
   Condiciones iniciales: $s(0) = 760,\ i(0) = 3$.
2: Resolver el sistema con `ParametricNDSolveValue` y obtener `modelo(`β`, `α`)`.
3: Definir `modelo2(`β`, `α`)` como evaluación del modelo para valores numéricos.
4: Definir `datos` como la lista de valores observados:
   $\{3, 8, 28, 75, 221, 291, 255, 235, 190, 125, 70, 28, 12, 5\}$.
5: Definir `tiempos` como el rango de tiempo `0..13`.
6: Definir la función de error:
   $error(\beta, \alpha) := \sum_{t=0}^{13} (I_{\text{modelo}}(t) - datos[t+1])^2$.
7: Minimizar el error con restricciones:
   $\min_{\beta,\alpha}\ error(\beta, \alpha)$ sujeto a $\beta \geq 0,\ \alpha \geq 0$.

Este nos arroja el siguiente resultado:

```
(* Resultado: {3901.18, {beta -> 0.00221909, alpha -> 0.450941}} *)
```

Veamos que tan bueno es el ajuste a través de graficar el modelo y solaparlo con los datos reales a través de los comandos 4.2.

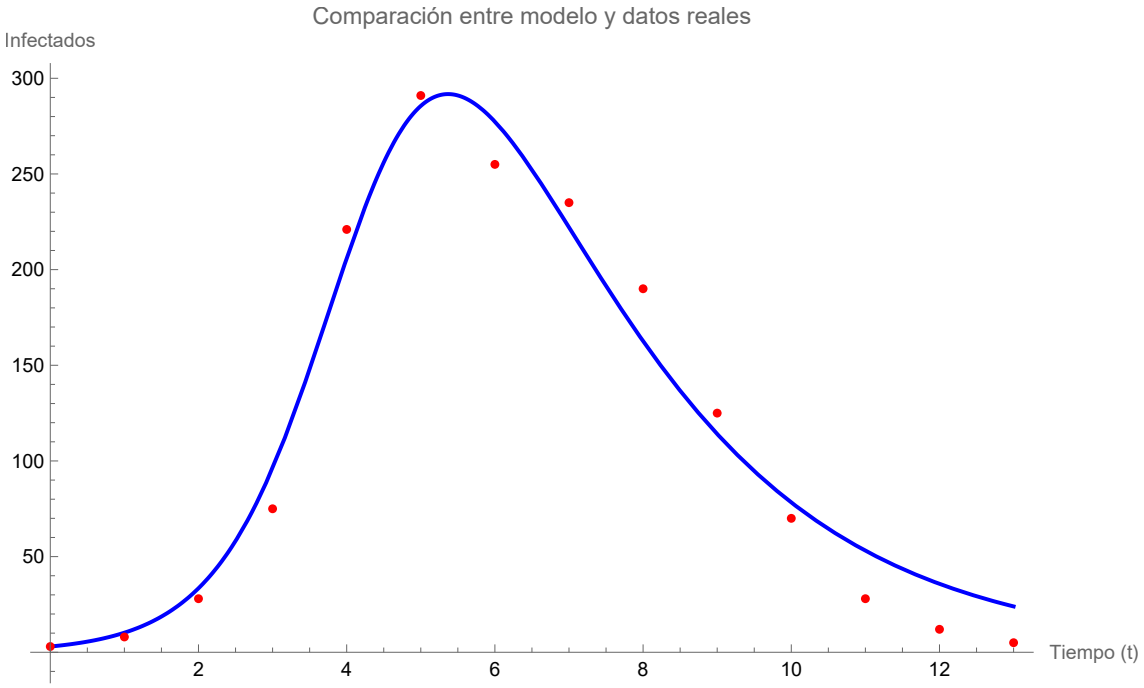

Figura 2.2: Ajuste para el Brote Inglés.

Como podemos observar el ajuste es notablemente bueno. ¿Por qué ha ocurrido esto? Como podemos observar en los datos, la epidemia no presenta picos de infección en ningún tramo de tiempo, la población se mantiene constante y no existe prácticamente dispersión en los datos, lo cual encaja a la perfección con las hipótesis del SIR, ya que este asume las tasas de recuperación y de transmisión constantes a lo largo de la epidemia. A continuación saquemos un par de conclusiones más.

Como podemos observar α es la tasa de recuperación por lo que $\frac{1}{\alpha}$ son los días que tarda un infectado en recuperarse. En este caso, $\alpha = 0{,}45$ y por tanto un infectado tarda 2,2 días en recuperarse.

Además, podemos introducior un nuevo elemento a nuestro estudio, el cual es el número de reproducción básico, R_0, el cual explicaremos con más detalle en el capítulo 3. Este número viene dado por $\frac{\beta N}{\alpha}$, donde N es la población total y nos da información sobre el número de personas a las que un infectado puede transmitir el virus. Si sustituimos por los valores que hemos obtenido anteriormente tenemos que $R_0 = 3{,}75$. Esto nos dice que la infección puede llegar a propagarse ampliamente sobre la población. Cuanto más grande es R_0, más difícil será controlar la epidemia, lo cual se ajusta bastante a la realidad, ya que la mayoría de estudiantes contrajeron la enfermedad.

La Plaga De Eyam

El pueblo de Eyam, en el condado de Derbyshire (Inglaterra), sufrió un brote de peste bubónica entre 1665 y 1666, originado probablemente a partir de la Gran

Peste de Londres. De los 350 habitantes originales, apenas 83 lograron sobrevivir tras dos oleadas epidémicas; la primera fue de intensidad moderada. Gracias a los registros minuciosos y al acuerdo colectivo de aislarse en cuarentena, este suceso se ha convertido en un caso de estudio clásico para evaluar modelos matemáticos de contagio.

En el caso de esta Plaga usaremos un método distinto que se basa en un resultado teórico que permite relacionar la tasa de transmisión con la tasa de recuperación. Esto es realmente interesante ya que dadas las definiciones de dichas tasas vemos que la tasa de transmisión β es generalmente difícil de estimar,ya que depende de la enfermedad que se estudie, factores sociales, conductuales, entre otros. Primero presentemos el resultado teórico.

Relación α y β

En el modelo SIR, R viene determinado una vez conocidos S e I, por lo que podemos prescindir de la ecuación de R. Nos queda el sistema

$$S' = -\beta\, S\, I. \tag{2.8}$$

$$I' = (\beta\, S - \alpha)\, I. \tag{2.9}$$

Observamos que el modelo solo tiene sentido mientras $S(t) \geq 0$ e $I(t) \geq 0$. Si cualquiera de ellos alcanza cero, consideramos el sistema terminado.

Veamos lo siguiente:

- Como $S' < 0$ para todo t, $S(t)$ es monótonamente decreciente.

- Luego $I' > 0$ si y solo si $S > \frac{\alpha}{\beta}$.

Por tanto, $I(t)$ crece mientras $S(t) > \alpha/\beta$, pero dado que S decrece, finalmente S cae por debajo de α/β, ya que de no hacerlo los infectados nunca pararían de crecer, lo cual es una contradiccón, y por tanto $I(t)$ disminuye hasta cero.

- Si $S(0) < \frac{\alpha}{\beta}$, entonces $I'(0) < 0$ e $I(t)$ decae desde el principio (no hay epidemia).
- Si $S(0) > \frac{\alpha}{\beta}$, entonces $I'(0) > 0$, $I(t)$ primero crece hasta un máximo alcanzado cuando $S = \frac{\alpha}{\beta}$, y luego decae a cero (se produce una epidemia).

Introducimos la cantidad umbral mencionada en la epidemia anteriormente estudiada

$$R_0 \;=\; \frac{\beta\, S(0)}{\alpha}.$$

llamada *número reproductivo básico.*

- Si $R_0 < 1$, la infección se extingue.
- Si $R_0 > 1$, se produce una epidemia.

La definición del número básico de reproducción R_0 es que representa el número de infecciones secundarias causadas por un único individuo infectado introducido en una población completamente susceptible de tamaño $K \approx S(0)$, a lo largo del curso completo de su infección.

En esta situación, un infectado realiza βK contactos por unidad de tiempo, todos ellos con personas susceptibles, y por tanto generan nuevas infecciones.

El periodo medio de infección es $1/\alpha$; por lo tanto, el número básico de reproducción es en realidad $\frac{\beta K}{\alpha}$, y no $\frac{\beta S(0)}{\alpha}$.

Llegados a este punto en lugar de intentar resolver S e I como funciones del tiempo t, dividimos las dos ecuaciones del modelo para obtener

$$\frac{I'}{S'} = \frac{dI}{dS} = \frac{(\beta S - \alpha)I}{-\beta SI} = -1 + \frac{\alpha}{\beta S}.$$

e integramos para encontrar las órbitas (curvas en el plano (S, I), o plano de fase)

$$I = -S + \frac{\alpha}{\beta} \log S + c. \tag{2.10}$$

donde c es una constante arbitraria de integración. Aquí utilizamos log para denotar el logaritmo natural. Otra forma de describir las órbitas es definir la función

$$V(S, I) = S + I - \frac{\alpha}{\beta} \log S.$$

y observar que cada órbita es una curva dada implícitamente por la ecuación $V(S, I) = c$, para cierto valor de la constante c. La constante c se determina a partir de los valores iniciales $S(0)$ e $I(0)$, respectivamente, ya que

$$c = V(S(0), I(0)) = S(0) + I(0) - \frac{\alpha}{\beta} \log S(0).$$

Nótese que el valor máximo de I en cada una de estas órbitas se alcanza cuando $S = \frac{\alpha}{\beta}$, lo cual se puede deducir fácilmente derivando e igualando la expresión 2.10 .

También se observa que, dado que ninguna de estas órbitas alcanza el eje I, se cumple que $S > 0$ para todo tiempo. En particular,

$$S_\infty = \lim_{t \to \infty} S(t) > 0.$$

lo cual implica que una parte de la población escapa a la infección.

Para terminar la prueba y llegar a la conclusión deseada, pensemos en una población de tamaño K en la que se introduce un pequeño número de infectados, de modo que $S_0 \approx K$, $I_0 \approx 0$, y $R_0 = \frac{\beta K}{\alpha}$.

Si usamos el hecho de que $\lim_{t\to\infty} I(t) = 0$, y llamamos $S_\infty = \lim_{t\to\infty} S(t)$, entonces la relación $V(S_0, I_0) = V(S_\infty, 0)$ nos da

$$K - \frac{\alpha}{\beta}\log S_0 = S_\infty - \frac{\alpha}{\beta}\log S_\infty.$$

de donde obtenemos una expresión para $\frac{\beta}{\alpha}$ en términos de las cantidades medibles S_0 y S_∞, siendo la siguiente:

$$\frac{\beta}{\alpha} = \frac{\log S_0 - \log S_\infty}{K - S_\infty}. \tag{2.11}$$

Podemos reescribir esto en términos de R_0(multiplicando por K) como la *relación de tamaño final*:

$$\log S_0 - \log S_\infty = R_0\left(1 - \frac{S_\infty}{K}\right). \tag{2.12}$$

En particular, dado que el lado derecho de la ecuación 2.12 es finito, el lado izquierdo también lo es, y esto demuestra una vez más que $S_\infty > 0$.

Las cantidades S_0 y S_∞ pueden estimarse mediante estudios serológicos (mediciones de respuestas inmunes en muestras de sangre) antes y después de una epidemia, y a partir de estos datos el número básico de reproducción R_0 puede estimarse usando la ecuación 2.12, con lo cual llegamos al objetivo de la demostración. No obstante analicemos más conclusiones.

Esta estimación es retrospectiva y solo puede determinarse una vez que la epidemia ha seguido su curso.

Inicialmente, el número de infectados crece exponencialmente porque la ecuación para I puede aproximarse por

$$I' = (\beta K - \alpha)I.$$

y la tasa de crecimiento inicial es

$$r = \beta K - \alpha = \alpha(R_0 - 1).$$

Esta tasa de crecimiento inicial r puede determinarse experimentalmente cuando comienza una epidemia. Entonces, dado que K y α pueden medirse, β puede calcularse como

$$\beta = \frac{r + \alpha}{K}.$$

Una conclusión adicional es que el número máximo de infectados en cualquier momento es el número de infectados cuando la derivada de I es cero, es decir, cuando $S = \alpha/\beta$. Este máximo está dado por

$$I_{\text{máx}} = S_0 + I_0 - \frac{\alpha}{\beta}\log S_0 - \frac{\alpha}{\beta} + \frac{\alpha}{\beta}\log\frac{\alpha}{\beta}.$$

obtenido al sustituir $S = \alpha/\beta$, $I = I_{\text{máx}}$ en 2.10.

Datos Plaga de Eyam

Una vez visto lo anterior debemos conocer los datos de La Plaga de Eyam para aplicarlos a las ecuaciones obtenidas. Usaremos los datos proporcionados por [5] que nos aporta a través del siguiente tabla:

Date (1666)	**Susceptibles**	**Infectives**
July 3/4	235	14
July 19	201	22
August 3/4	153	29
August 19	121	21
September 3/4	108	8
September 19	97	8
October 4/5	Unknown	Unknown
October 20	83	0

Cuadro 2.4: Tabla de datos de La Plaga de Eyam proporcionada por [5].

En la tabla se considera el tiempo incial a inicios de julio, sin embargo el texto proporcionado por [5] nos indica que el período de estudio va de mediados de mayo a mediados de octubre con $S(0) = 254$ susceptibles e $I(0) = 7$ infectados. Por este motivo agregamos este datos a nuestra tabla para poder realizar el análisis con todos los datos de los que disponemos, obteniendo la siguiente tabla:

Fecha (1666)	**Susceptibles**	**Infectados**
19 de mayo	254	7
3/4 de julio	235	14
19 de julio	201	22
3/4 de agosto	153	29
19 de agosto	121	21
3/4 de septiembre	108	8
19 de septiembre	97	8
4/5 de octubre	Desconocido	Desconocido
20 de octubre	83	0

Cuadro 2.5: Datos completos de La Plaga de Eyam.

Vemos que los períodos donde se realiza el recuento son aproximadamente cada medio mes, salvo dos saltos de tiempo que se dan al principio y al final del estudio debido al desconocimiento de susceptibles en infectados en dichos períodos. Realicemos un mapeo de los datos identificando el primer dato con $t = 0$ y realizando los saltos correspondientes teniendo en cuenta que entre t y $t+1$ hay una distancia aproximada de un mes. De esta forma obtenemos la tabla definitiva para nuestro estudio:

t	$S(t)$	$I(t)$
0	254	7
1.5	235	14
2.03	201	22
2.53	153	29
3.07	121	21
3.57	108	8
4.1	97	8
5.17	83	0

Cuadro 2.6: Datos de la plaga de Eyam indexados por tiempo t en meses.

Una vez tenemos limpios y controlados los datos de la epidemia realizaremos el cálculo de los parámetros a partir de los valores extraídos. En este caso $S_0 = 254$, $S_\infty = 83$ y $\alpha = 2{,}73$, dado que conocemos que el período infectivo es 11 días, lo cual equivale a 0,3667 meses. De esta manera queda automáticamente determinado β que en este caso es 0,0178.

Al igual que en el caso del Brote de Inglaterra, vamos a graficar los datos reales de La Plaga de Eyam y a superponerlos con las funciones obtenidas en nuestro modelo.

Para ello usaremos el código 4.2 y veamos el ajuste desde distintas perspectivas.

Infectados

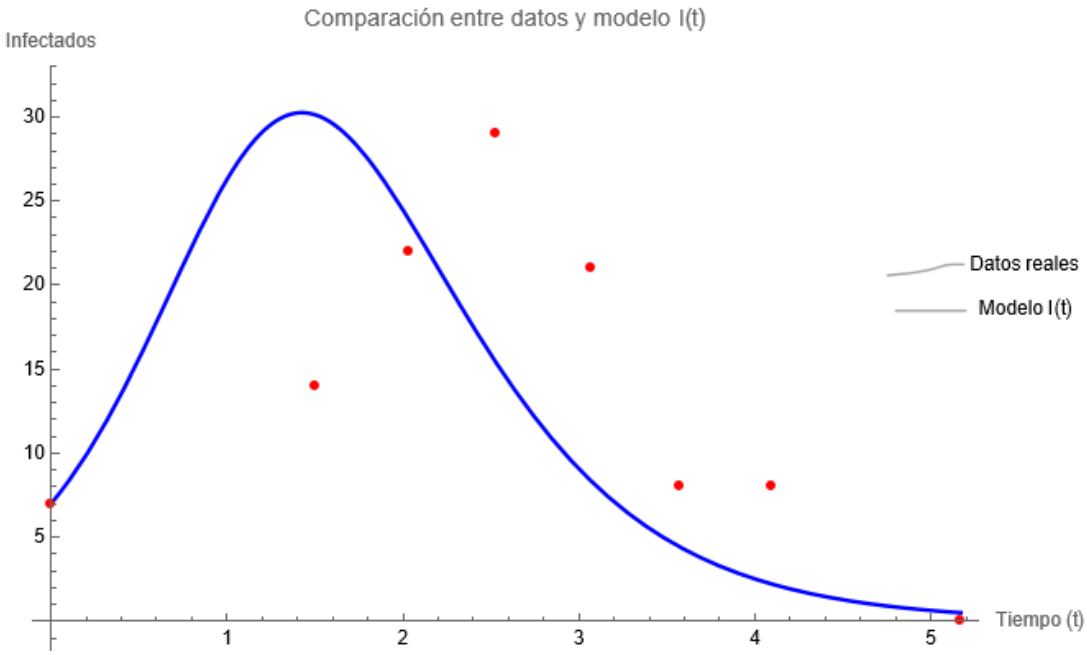

Figura 2.3: Ajuste Plaga de Eyam Infectados.

Susceptibles

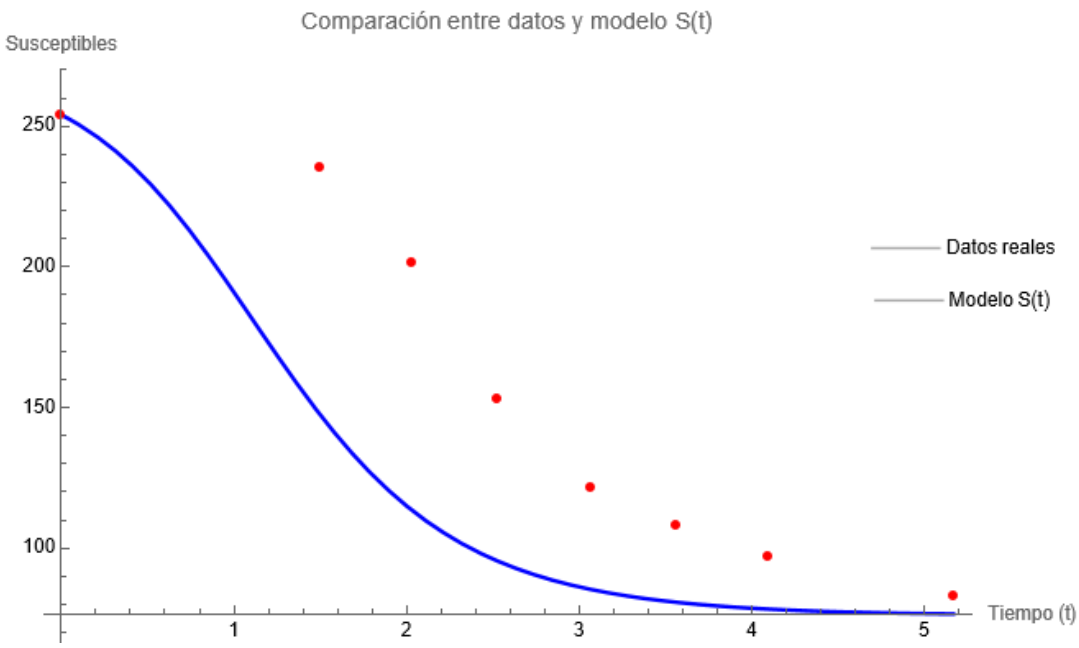

Figura 2.4: Ajuste Plaga de Eyam Susceptibles.

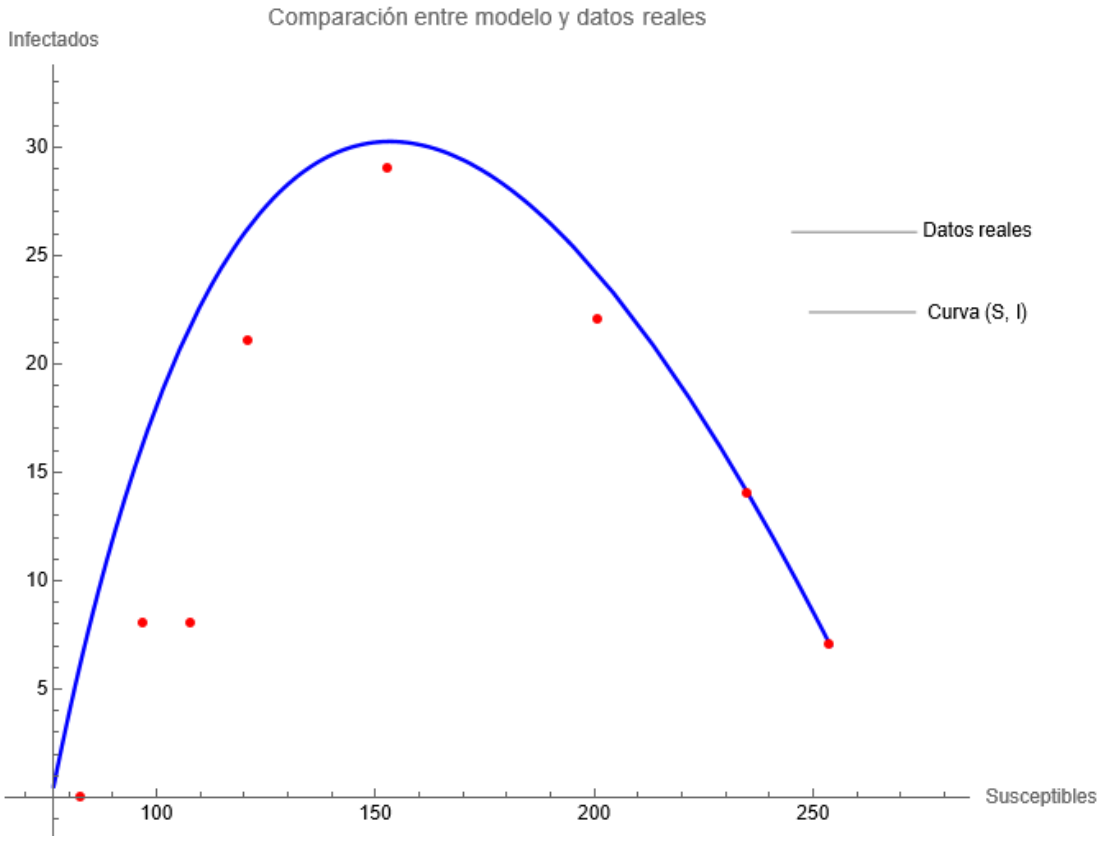

Figura 2.5: Comparación comportamiento de la epidemia real con la modelada.

Como podemos observar el modelo no se ajusta bien a los datos de nuestra Plaga a pesar de que la curva descrita por nuestro modelo parece simplemente estar desplazada en las tres gráficas. ¿Por qué el ajuste no es certero? A diferencia de en La Gripe de Inglaterra aquí en los datos si que se pueden observar picos de infección, y algo más de dispersión en los datos, con lo cual el modelo SIR no es capaz de ajustarse a los datos y comente más errores provocando una mayor distancia entre los puntos en la gráfica. Por otro lado cabe recalcar también que nuestro modelo asume que la infección se transmite directamente entre personas. Aunque esto es posible, no es lo más realista posible, la peste bubónica se transmite principalmente por pulgas de ratas. Cuando una rata infectada es mordida por una pulga, ésta se vuelve extremadamente hambrienta y pica repetidamente al hospedador, propagando la infección en la rata. Cuando la rata hospedadora muere, sus pulgas pasan a otras ratas, extendiendo aún más la enfermedad. A medida que disminuye el número de ratas disponibles, las pulgas buscan hospedadores humanos, y así es como la peste comienza en una población humana. Sería realmente interesante encontrar un modelo que incorpore transmisión vectorial (pulgas-ratas-humanos), así como cambios de comportamiento social (como la cuarentena autoimpuesta), los cuales permitan capturar de forma más precisa la verdadera naturaleza del brote en Eyam.

Tal modelo requeriría nuevas variables o compartimentos, posiblemente incorporando categorías como vectores infecciosos, hospedadores intermedios, o incluso variables dinámicas que representen el contacto social reducido, el miedo, la infor-

mación disponible o las decisiones comunitarias.

También sería clave introducir retardos temporales en la infección y mortalidad, reflejando la biología real del patógeno.

Dada esta situación predecimos que aún utilizando el método de mínimos cuadrados, al igual que en el Brote de Inglaterra, el modelo será incapaz de ajustarse correctamente dada la naturaleza de los datos y que en ese método dispone de menos datos e información conocida de la epidemia.

Para calibrar los parámetros α y β para La Plaga de Eyam usaremos un código similar al usando en la Gripe Inglesa 4.2, actualizando simplemente los datos.

El resultado que nos arroja es el siguiente:

```
(* Resultado: {52.4189, {beta -> 0.0097074, alpha -> 1.5569}} *)
```

Veamos que tan bueno es el ajuste a través de graficar el modelo y solaparlo con los datos reales a través de los comandos 4.2 con una ligera modificación.

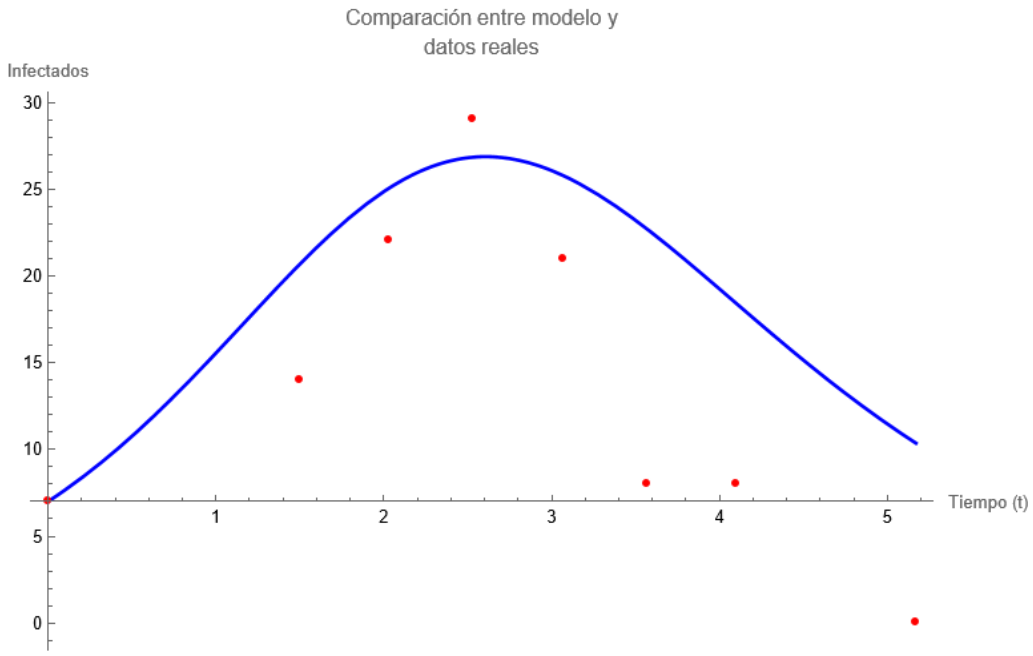

Figura 2.6: Ajuste mínimos cuadrados para La Plaga de Eyam

Como habíamos anticipado, el modelo no ajusta bien nuestro datos, dadas las condiciones anteriormente mencionadas. No obstante esperamos que este análisis detallado y ejemplificado del modelo SIR sirva como primer paso en la búsqueda de otros tipos de modelos o variantes que describan de manera adecuada una epidemia de esta índole.

Capítulo 3

Modelización de la incidencia delictiva

A continuación presentaremos un modelo para describir el comportamiento de la actividad delictiva y así poder explicar su crecimiento a través de su tratamiento como fenómeno que se transmite por contacto social. Definiremos los comparimentos en los que dividiremos a la población y los parámetros que usaremos para modelar la criminalidad de dicha población, además de justificar el buen planteamiento del modelo y el posterior análisis de los resultados obtenidos.

3.1. Explicación del Modelo

En este modelo se clasifica a la población en tres grupos: las personas que no cometen delitos o inocentes, los delincuentes que están libres y los delincuentes que se encuentran encarcelados. Un "delincuente" se entiende como alguien que realiza una acción ilícita que exige intervención de las autoridades (por ejemplo, una sanción económica, trabajos comunitarios o privación de libertad). Sin embargo, en un momento dado, es posible que un delincuente no esté en prisión, ya sea porque aún no ha sido detenido, porque se encuentra en libertad mientras espera juicio o resolución, o porque cumple una condena que no conlleva reclusión.

Se denotan por $S(t)$ al conjunto de no delincuentes, por $L(t)$ al de delincuentes libres y por $P(t)$ al de delincuentes encarcelados, en el instante $t \geq 0$. Estos tres compartimentos abarcan a todas las personas de la región estudiada, y el modelo describe cómo fluyen los individuos entre ellos, utilizando relaciones tanto lineales como no lineales respecto a las cantidades de cada grupo.

Una de las suposiciones más importantes que asume nuestro modelo es que los delincuentes libres $L(t)$ afectan a los no delincuentes (personas susceptibles) a través de las interacciones sociales [3, 7]. En este enfoque, la "propagación" del comportamiento delictivo es tratada de forma dinámica: se simplifica asumiendo que la única vía para que un individuo pase a ser delincuente es mediante el contacto con alguien

que ya lo sea,es decir, una transmisión de tipo acción de masas, lo cual significa que cada susceptible tiene la misma probabilidad de encontrarse con un infectado, en términos analíticos (Incidencia = $\beta\frac{SI}{N}$). Este punto de vista global permite, por un lado, determinar de manera analítica un equilibrio sin delincuencia y, por otro, hallar un umbral que distingue situaciones de baja o alta prevalencia delictiva, es decir, según el tamaño de la población.

Al mismo tiempo, el modelo se mantiene lo suficientemente sencillo como para poder ajustarlo a datos reales de población penitenciaria. Además, se adopta la hipótesis de mezclado homogéneo trabajando con valores promedio de los compartimentos, sin diferenciar entre edades, géneros, zonas geográficas, tipos de infracción y/o categorías delictivas. Además todos los individuos se relacionan con la misma probabilidad entre sí [8]. De este modo, la dinámica criminológica queda reducida a un esquema tractable que captura las ideas esenciales del proceso.

- Un individuo susceptible puede volverse delincuente o no por contacto social (convencido o presionado, imita una actitud bajo un estímulo, etc.). Es realista suponer que, durante algún tiempo (al menos algunos minutos, horas o días), el individuo no está en prisión porque no ha sido arrestado. La "fuerza de infección" está contenida en el parámetro $\beta > 0$.

- Un delincuente en libertad puede o no pasar al subgrupo de encarcelados (condenado en prisión). El tiempo medio de transición a prisión es $1/a_2$, donde $a_2 > 0$ es la tasa de encarcelamiento. Este tiempo considera el periodo hasta ser detenido y el tiempo hasta el juicio y la sentencia definitiva. Algunos delincuentes no van a prisión, mientras que otros sí; el parámetro $1/a_2$ es un promedio simplificado de esos casos.

- Un delincuente que no está en prisión puede regresar a la clase de no-delincuentes, bien porque nunca fue detenido por la policía pero decide no cometer más delitos (desistencia), o bien porque ha sido declarado inocente, o porque ya cumplió una sanción fuera de la cárcel (multa, servicios comunitarios, etc.). El tiempo medio de transición a no-delincuente es $1/a_1$, donde $a_1 > 0$ es la tasa de recuperación.

- Un delincuente condenado regresa a la clase de no-delincuentes después de un tiempo promedio $1/r$ en prisión, donde $r > 0$ es la tasa de liberación. Aunque algunos prisioneros puedan pasar a la libertad condicional estando aún en prisión, se asume como buena aproximación a la realidad que, durante algún tiempo (como mínimo algunos minutos, horas o días), no se repiten infracciones. Esta simplificación reduce la dimensionalidad del modelo matemático.

- Hay una entrada de población (nacimientos, inmigración, etc.) con parámetro $\lambda > 0$. También existe una salida (muertes, emigración, etc.) con tasa $\mu > 0$, donde $1/\mu$ es el tiempo medio de vida en el sistema. Aproximadamente, $1/\mu$ es la esperanza de vida en la sociedad en estudio. Se asume que la población total es igual a λ/μ.Por supuesto, esto es una simplificación de la realidad, ya

que suponemos que los ingresos son aproximadamente iguales a las tasas de salida, sin embargo la población constante permite trabajar con proporciones de tamaño de compartimentos en un escenario bidimensional y obtener un sistema autónomo factible.

Todos estos parámetros de transición se asumen constantes en el tiempo [8]. El modelo matemático correspondiente se representa mediante el siguiente sistema de tres ecuaciones diferenciales ordinarias:

$$\begin{aligned} \frac{dS}{dt} &= \lambda \;-\; \beta\, S\, L \;+\; r\, P \;+\; a_1\, L \;-\; \mu\, S, \\ \frac{dL}{dt} &= \beta\, S\, L \;-\; a_1\, L \;-\; a_2\, L \;-\; \mu\, L, \\ \frac{dP}{dt} &= a_2\, L \;-\; r\, P \;-\; \mu\, P. \end{aligned} \tag{3.1}$$

Se asumen tres condiciones iniciales:

$$S(0) = S_0, \qquad L(0) = L_0, \qquad P(0) = P_0.$$

Obsérvese que, si $N(t) = S(t) + L(t) + P(t)$ es la población total, entonces

$$\frac{dN}{dt} \;=\; \frac{dS}{dt} + \frac{dL}{dt} + \frac{dP}{dt} \;=\; \lambda \;-\; \mu\, N \;\Longrightarrow\; N(t) \;=\; \Big(N_0 - \frac{\lambda}{\mu}\Big)\, e^{-\mu\, t} \;+\; \frac{\lambda}{\mu} \tag{3.2}$$

Cuando $N_0 = \lambda/\mu$, la población permanece constante y su tamaño es

$$N(t) \;=\; N \;=\; \frac{\lambda}{\mu}.$$

A pesar de que el modelo (3.1) es homogéneo, se puede argumentar que solo una proporción

$$\widetilde{S}(t) = (1-\alpha)\, S(t), \quad \alpha \in (0,1),$$

puede volverse criminalmente activa, porque hay niños, por ejemplo. Entonces

las ecuaciones para $\widetilde{S}, L, P$ quedan:

$$\begin{aligned}
\frac{d\widetilde{S}}{dt} &= \lambda - \beta\widetilde{S}\,L + r\,P + a_1\,L - \mu\,\widetilde{S},\\
\frac{dL}{dt} &= \beta\,\widetilde{S}\,L - a_1\,L - a_2\,L - \mu\,L,\\
\frac{dP}{dt} &= a_2\,L - r\,P - \mu\,P,
\end{aligned}$$

donde $\widetilde{\beta} = \beta\,(1-\alpha)$ es la fuerza de influencia sobre el subtipo L. El coeficiente β es $\widetilde{\beta} = \beta\,(1-\alpha)$ y (3.1) es adecuado. El uso de parámetros promedio permite obtener una visión general del fenómeno en estudio.

3.1.1. Justificación de la positividad del modelo

El siguiente resultado justifica que el modelo (3.1) está bien planteado. La demostración se basa en [[9], Lema 3.1–3.3], donde los autores probaron la existencia de una solución adecuada para un modelo quimiostático no autónomo y para un modelo SIR no autónomo.

Teorema 1. *Si $S(0) = S_0$, $L(0) = L_0$ y $P(0) = P_0$ son positivos, entonces $S(t)$, $L(t)$ y $P(t)$ son positivas para todo $t > 0$.*

Demostración. Partimos de la segunda ecuación en (3.1):

$$\frac{dL}{dt} \;=\; \big(\beta\,S - a_1 - a_2 - \mu\big)\,L \;\Longrightarrow\; L(t) = L_0\,e^{\int_0^t \left(\beta\,S(s) - a_1 - a_2 - \mu\right)\,ds} > 0.$$

Para $S(t)$ y $P(t)$, supongamos que alguno de ellos se hace negativo en algún instante de tiempo. Entonces debe cruzar el valor cero. Sea $t_1 > 0$ el primer instante en que S o P desaparecen. Si $P(t_1) = 0$, entonces, de la tercera ecuación en (3.1),

$$\left.\frac{dP}{dt}\right|_{t=t_1} = a_2\,L(t_1) > 0,$$

lo cual es una contradicción. Si $S(t_1) = 0$, entonces, de la primera ecuación en (3.1),

$$\left.\frac{dS}{dt}\right|_{t=t_1} = \lambda + r\,P(t_1) + a_1\,L(t_1) > 0,$$

lo cual también es una contradicción. Por tanto, se concluye que $S(t) > 0$ y $P(t) > 0$ para todo $t > 0$. □

3.2. Dinámica del Modelo

Veamos en esta sección del capítulo la importancia del número básico de reproducción, su definición y formas de calcularlo, además de como influye en el estudio del comportamiento de la actividad delictiva.

3.2.1. Número Básico de Reproducción R_0

En el modelado de epidemias, el número básico de reproducción R_0 es el número promedio de casos secundarios producidos por un individuo infectado introducido en una población de individuos susceptibles. Cuando solo una proporción $p \in [0, 1]$ de los individuos es susceptible y el resto es inmune, el número de reproducción efectivo

$$R_e = p\, R_0$$

es el número promedio de casos secundarios producidos por un individuo infectado. En la práctica, el valor de R_0 para una enfermedad específica no puede deducirse directamente de los datos y depende de muchas variables, como la ubicación, la densidad y la movilidad de la población. Sin embargo, para modelos sencillos puede calcularse, ya sea por su significado epidemiológico o mediante el método de la matriz de próxima generación [10, 11].

El número básico de reproducción no se limita a epidemias virales; puede utilizarse para actitudes socialmente contagiosas, como el comportamiento delictivo. En nuestro planteamiento, el número básico de reproducción R_0 es el número promedio de delincuentes secundarios que surgen a partir de un delincuente introducido en una población de individuos susceptibles. Sin embargo, a diferencia de las enfermedades infecciosas (como las descritas por las ecuaciones SIR [13]), el concepto de número de reproducción efectivo no se utiliza aquí porque no existe inmunidad adquirida.

Interpretación Social

Calculemos R_0 desde su interpretación social. Durante la primera unidad de tiempo, si $S = N$ y $L = 1$, la variación de susceptibles viene dada por:

$$\frac{dS}{dt} = \lambda - \beta\, S\, L + r\, P + a_1\, L - \mu\, S.$$

Como es "la primera unidad de tiempo", despreciamos nacimientos (λ) y muertes naturales (μ) frente al impacto inmediato de la transmisión, y no hay P que regenere susceptibles ($rP = 0$).

Además, al principio no hay recuperaciones ($a_1 L$) significativas en ese instante mínimo, así que esa parte la podemos ignorar para entender la tasa inicial de contagio.

Bajo estas hipótesis cae todo excepto el término de transmisión:

$$\frac{dS}{dt} \approx -\,\beta\, S\, L \quad \Longrightarrow \quad \frac{dS}{dt}\Big|_{S=N,\, L=1} = -\beta\, N.$$

Es decir, en cada unidad de tiempo ese único delincuente "convierte" a βN individuos susceptibles en nuevos "delincuentes".

La fracción de la población en L sale de esa clase con tasa total

$$a_1 + a_2 + \mu$$

(recuperaciones a_1, paso a otra forma de la conducta a_2 o "muerte"/abandono μ). Por tanto, la duración media que un individuo pasa en L es

$$\frac{1}{a_1 + a_2 + \mu}.$$

En el modelado de contagios (infecciosos o sociales), como hemos explicado anteriormente, el número básico de reproducción R_0 se define como:

$$\underbrace{\big(\text{nuevos casos por unidad de tiempo}\big)}_{\beta N} \times \underbrace{\big(\text{tiempo medio de contagiosidad}\big)}_{1/(a_1+a_2+\mu)} = \frac{\beta\, N}{a_1 + a_2 + \mu}.$$

Esta ecuación nos da el número total esperado de "infecciones" (o delincuentes secundarios) que genera un solo individuo durante todo el tiempo que permanece en la fase contagiosa.

Luego:

$$R_0 = \frac{\beta N}{a_1 + a_2 + \mu} \tag{3.3}$$

Método Matriz Nueva Generación

Este valor de $\mathcal{R}_0$ también puede obtenerse mediante el método de la matriz de próxima generación [10, 11]. En la notación empleada allí, se cumplen las condiciones [[11], (A1)–(A5), p. 161] con:

$$\mathcal{F}_1 = \beta S L, \quad \mathcal{V}_1 = (a_1 + a_2 + \mu) L,$$
$$\mathcal{F}_2 = 0, \quad \mathcal{V}_2 = -a_2 L + rP.$$

El significado social de estas variables es el siguiente: $\mathcal{F}_1$ es la tasa de aparición de nuevos infractores en L, $\mathcal{F}_2$ es la tasa de aparición de nuevos infractores en P (es 0 porque las personas en L ya son infractores), y $\mathcal{V}_i$ es la tasa de las otras transiciones, $i \in \{1, 2\}$. Dado el equilibrio libre de crimen CFE $= (N, 0, 0)$ y las matrices:

$$F = \begin{pmatrix} \frac{d\mathcal{F}_1}{dL}(N,0,0) & \frac{d\mathcal{F}_1}{dP}(N,0,0) \\ \frac{d\mathcal{F}_2}{dL}(N,0,0) & \frac{d\mathcal{F}_2}{dP}(N,0,0) \end{pmatrix} = \begin{pmatrix} \beta N & 0 \\ 0 & 0 \end{pmatrix},$$

$$V = \begin{pmatrix} \frac{d\mathcal{V}_1}{dL}(N,0,0) & \frac{d\mathcal{V}_1}{dP}(N,0,0) \\ \frac{d\mathcal{V}_2}{dL}(N,0,0) & \frac{d\mathcal{V}_2}{dP}(N,0,0) \end{pmatrix} = \begin{pmatrix} a_1 + a_2 + \mu & 0 \\ -a_2 & r \end{pmatrix},$$

la matriz de próxima generación es FV^{-1} y $\mathcal{R}_0 = \rho(FV^{-1})$, donde ρ es el radio espectral.

Existen resultados que establecen que $\mathcal{R}_0 = 1$ es el punto crítico para la estabilidad del CFE. Intuitivamente, si $\mathcal{R}_0 > 1$, entonces cada infractor influye en más de una persona, hay brotes y la criminalidad persiste. Por el contrario, si $\mathcal{R}_0 < 1$, entonces cada infractor influye en menos de una persona y la criminalidad desaparece al final.

Estos resultados son los siguientes:

Teorema 2. *[11][Teorema 1]: El CFE es localmente asintóticamente estable si $\mathcal{R}_0 < 1$, pero inestable si $\mathcal{R}_0 > 1$.*

Demostración. Consultar Apéndice 4 □

Teorema 3. *Si $\mathcal{R}_0 \leq 1$, entonces el CFE es globalmente asintóticamente estable para el sistema 3.1 en $[0, N]^3$.*

Demostración. Consultar Apéndice 5 □

Interpretamos los Teoremas 4 y 5 desde el punto de vista de las epidemias sociales. Estos indican que si $\mathcal{R}_0$, dado por la ecuación 3.3, es menor o igual que 1, entonces la criminalidad se erradica a largo plazo. En términos simples, si el CFE (Crime-Free Equilibrium) es asintóticamente estable, entonces las perturbaciones (por ejemplo, si una persona comete un delito o se convierte en infractora) no alteran permanentemente el sistema, es decir, si comienzas cerca del CFE, las soluciones del sistema convergen nuevamente hacia el CFE cuando $t \to \infty$ de manera que con el tiempo el sistema volverá al estado libre de crimen. Al contrario si el CFE no es asintóticamente estable, si introduces una perturbación (una persona se convierte en infractora), el crimen no desaparece y el numero de infractores se mantiene positivo de manera permanente.

3.3. Calibración de los Parámetros

En esta sección del capítulo pondremos a prueba nuestro modelo con los datos de personas encarceladas entre los años 2009 y 2019 en España, buscando ver que tan bien ajusta los datos y que capacidad predictiva tiene.

3.3.1. Crimen en España Período 2009-2019

Hasta ahora, hemos tratado el sistema 3.1 desde un punto de vista cualitativo, analizando patrones del crimen y haciendo énfasis en el número básico de reproducción y lo importante que es para llegar a predecir el comportamiento delictivo. En la última sección analizaremos medidas y propuestas que se podrían tomar a nivel político e institucional para bajar las tasas de criminalidad.

Sin embargo en esta sección calibraremos los parámetros de nuestro modelo basándonos en datos reales del Ministerio del Interior de España (consulta `https://www.epdata.es/`) con respecto al número de personas en prisión por año (en un instante determinado del tiempo en diciembre) en España, véase la tabla siguiente 3.3.1. El objetivo es ajustar el modelo propuesto a este conjunto de datos, obtener los parámetros de entrada y realizar un análisis de sensibilidad.

Datos reales sobre el número de personas en prisión por año (en un instante determinado en diciembre) en España.

Año	Personas en prisión	Año	Personas en prisión
2009	76,079	2015	61,614
2010	73,929	2016	59,589
2011	70,472	2017	58,814
2012	68,597	2018	58,883
2013	66,765	2019	58,517
2014	65,017		

Fuente: Ministerio del Interior de España (véase `https://www.epdata.es/`).

En el modelo 3.1, la variable de tiempo t se mide en años, donde $t = 0$ corresponde al año 2009.

Según datos oficiales del Consejo General del Poder Judicial (véase `https://www.epdata.es/`) el tiempo medio en prisión en España es de alrededor de 18 meses, por lo que estimamos $r = 1/1{,}5$ y el tiempo medio de los procesos judiciales en los Juzgados de Primera Instancia e Instrucción es de 7 meses para acciones civiles y 2,3 meses para acciones penales con prisión.

Tiempos similares se dan en la Audiencia Provincial. Por tanto, fijamos $a_1 = 12/7$ y $a_2 = 12/2{,}3$.

Consideramos la población media en España entre los años 2009 y 2019: 46.686.994 habitantes. Dividimos los datos de la tabla 3.3.1 entre 46.686.994, de forma que trabajamos con proporciones y tenemos $N = 1$. También fijamos la condición inicial $P_0 = 76{,}079/46{,}686{,}994$ como la proporción de personas encarceladas en el año 2009, según la tabla 3.3.1.

Finalmente, considerando una esperanza de vida de aproximada de 82 años, definimos $\lambda = \mu = 1/82$. Una vez establecida esta información previa, los dos parámetros restantes, β y S_0, se estiman mediante minimización por mínimos cuadrados, siguiendo la metodología mencionada en [14]. Es decir, si $d_0, \ldots, d_{10}$ son las proporciones obtenidas a partir de la tabla 3.3.1, buscamos minimizar la siguiente expresión:

$$(\beta, S_0) \mapsto \sum_{t=0}^{10} (P(t) - d_t)^2. \tag{4}$$

Nótese que, dado P_0 tomado de la tabla y S_0 obtenido del procedimiento de minimización, la condición inicial restante L_0 queda completamente determinada por la relación $L_0 = 1 - P_0 - S_0$.

Realicemos la calibración de los parámetros mediante el código 4.2 cuyo pseudocódgio es el siguiente:

Algorithm 2 Ajuste de parámetros para modelo SLP

1: Definir el modelo como sistema de EDOs:

$$s'(t) = \frac{1}{82} - \beta s(t)l(t) + \frac{2}{3}p(t) + \frac{12}{7}l(t) - \frac{1}{82}s(t).$$
$$l'(t) = \beta s(t)l(t) - \frac{12}{7}l(t) - \frac{12}{2{,}3}l(t) - \frac{1}{82}l(t).$$
$$p'(t) = \frac{12}{2{,}3}l(t) - \frac{2}{3}p(t) - \frac{1}{82}p(t).$$

Condiciones iniciales: $s(0) = S_0, \quad l(0) = 1 - \frac{76079}{46686994} - S_0, \quad p(0) = \frac{76079}{46686994}.$

2: Resolver el sistema con `ParametricNDSolveValue` y obtener `modelo`(β, S_0).

3: Definir `modelo2`(β, S_0) como evaluación del modelo para valores numéricos.

4: Definir `datos` como la lista de valores observados:

$$\left\{\frac{76079}{46686994}, \frac{73219}{46686994}, \frac{70472}{46686994}, \ldots, \frac{58814}{46686994}, \frac{58583}{46686994}, \frac{58517}{46686994}\right\}$$

.

5: Definir `tiempos` como el rango de tiempo `0..10`

6: Definir la función de error:

$$\text{error}(\beta, S_0) := \sum_{t=0}^{10} \left(P_{\text{modelo}}(t) - \text{datos}[t+1]\right)^2$$

.

7: Minimizar el error con restricciones:

$$\min_{\beta, S_0} \text{error}(\beta, S_0) \quad \text{sujeto a } \beta \geq 0,\ 0 \leq S_0 \leq 1$$

.

Este nos arroja el siguiente resultado:

```
(* Resultado: {4.59182*10^-9, {beta -> 6.92912, S0 -> 0.998173}} *)
```

Podemos observar que en este caso, a diferencia de los dos anteriores donde hemos ajustado por mínimos cuadrados si que hemos puesto una cota superior a uno de los parámetros, en este caso S_0, ya que estamos trabajando con proprociones al haber dividido por la población total.

Con todo esto tenemos los valores de todos los parámetros necesarios para simular nuestro modelo:

$$\beta = 6{,}92912, \quad S_0 = 0{,}998173; \quad r = 1/1{,}5, \quad a_1 = 12/7, \quad a_2 = 12/2{,}3, \quad \lambda = \mu = 1/82.$$

No es difícil pensar que la aproximación será buena dado que el valor del error que nos devuelve $NMminimize$ es $4{,}59182 \cdot 10^{-9}$, el cual es la suma de los errores que se cometen en cada punto entre el modelo y los datos reales, y vemos que es realmente pequeño, luego nuestro ajuste no distará demasiado de los datos reales.

Grafiquemos todo el ajuste a través del siguiente código 4.2 y veamos los resultados.

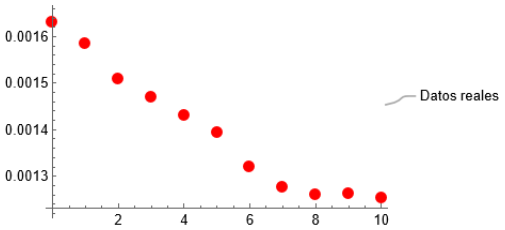

Figura 3.1: Datos reales crimen en España 2009-2019

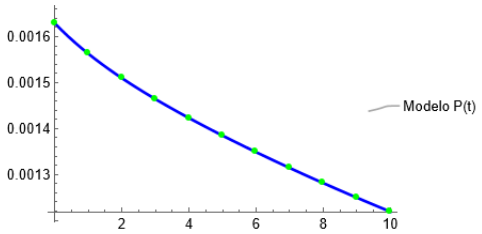

Figura 3.2: Modelo crimen en España 2009-2019

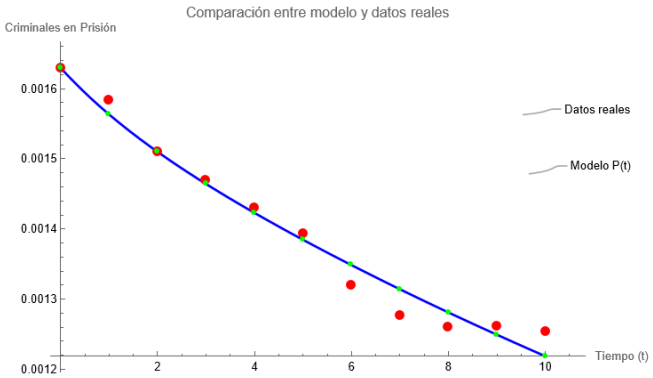

Figura 3.3: Comparación modelo con datos reales

Por el momento podemos observar que en nuestro ajuste es notablemente bueno, sobretodo al principio. Si nos fijamos al igual que los ejemplos vistos en el capítulo 2, el modelo ajusta un poco peor en el momento en el que los datos pierden «continuidad» , ya que los encarcelados empiezan a disminuir con menor frecuencia.

3.4. Capacidad Predictiva del Modelo

Previamente hemos ajustado el modelo para ver que tan bien aproxima nuestro datos reales. Sin embargo ahora lo que intentaremos es evaluar la capacidad predicitiva del modelo. Para ellos en vez de ajustar con todos los datos ajustaremos con una parte de ellos, en primer lugar tomaremos datos hasta 2012 y posteriormente hasta 2016.

3.4.1. Período 2009-2012

Para estudiar ambos períodos, calibraremos los parámetros por el mismo método, el de mínimos cuadrados, siguiente la misma expresión de siempre:

$$(\beta, S_0) \mapsto \sum_{t=0}^{T} (P(t) - d_t)^2$$

Lo que va a variar es el valor T, el cual en este primer caso es $T = 3$ dado que estudiamos 4 años, para la calibración usaremos un código similar al anterior 4.2, simplemente realizaremos una variación de los datos.

Los valores de los parámetros que nos arroja son los siguientes:

```
(* Resultado: {1.92626*10^-10, {beta -> 6.91778, S0 -> 0.998168}} *)
```

Con estos valores de β y S_0, más los otros que eran fijos podremos simular el ajuste y predecir la criminalidad en España para los años posteriores. Grafiquemos con 4.2.

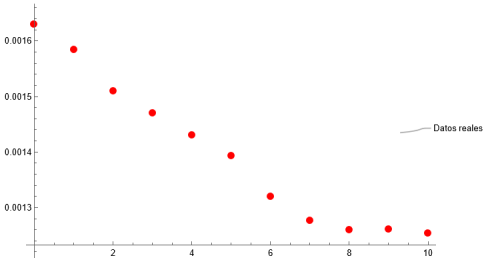

Figura 3.4: Datos reales crimen en España 2009-2019

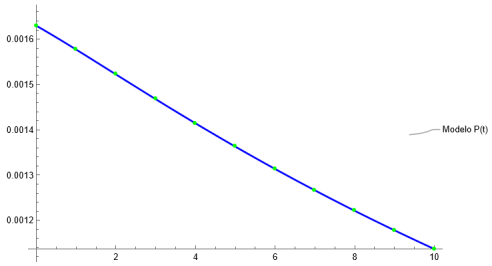

Figura 3.5: Modelo predictivo crimen en España 2012

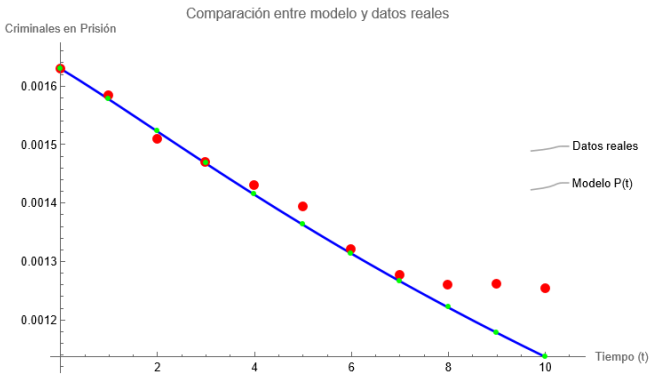

Figura 3.6: Comparación modelo con datos reales

En este caso hemos podido observar que para estos datos de los 4 primeros años los valores de los parémetros son los siguientes: $\beta = 691778$ y $S_0 = 0{,}998168$. Simulando el modelo con estos datos vemos que se consigue una muy buena predicción

hasta el año 2016 y que a partir de allí, por lo comentado anteriormente nuestro modelo no es tan bueno en la predicción de la actividad delictiva. En este caso que el error que nos devuelve $NMinimize$ es 1,9262610¯10, que a pesar de ser más pequeño que el anterior, no significa nada ya que aquí simplemente está tomando los datos de los 4 primeros años, con lo cual es obvio que se ajustara más a esos datos en ese período que el modelo ajustado a los 11 años pero para evaluar la capacidad predictia del modelo no nos sirve para nada.

3.4.2. Período 2009-2016

Aplicaremos la misma lógica del apartado anterior pero esta vez con $T = 7$. Usando 4.2 obtenemos que los valores de los parámetros son:

```
(* Resultado: {7.89687*10^-10, {beta -> 6.9205, S0 -> 0.998168}} *)
```

Luego las gráficas dadas por 4.2 son las siguientes:

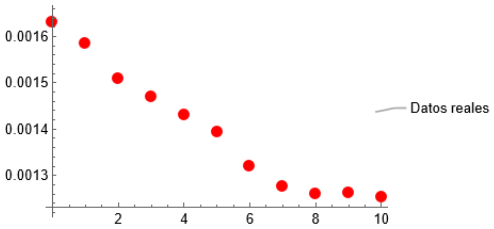

Figura 3.7: Datos reales crimen en España 2009-2019

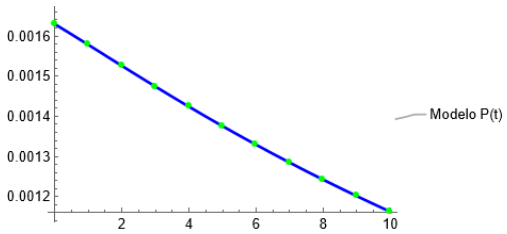

Figura 3.8: Modelo predictivo crimen en España 2016

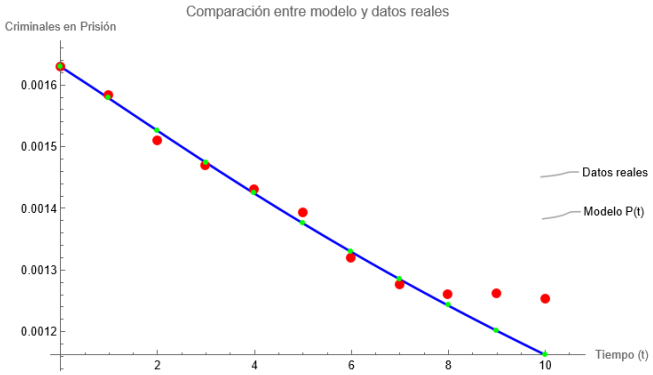

Figura 3.9: Comparación modelo con datos reales

Como podemos observar al haber aumentado 4 años para predecir los siguientes 3 que nos faltaban 2017, 2018 y 2019 el ajuste ha mejorado respecto a si tomábamos solo hasta 2012, lo cual era lógico pensarlo

Solapemos los 4 casos para concluir este análisis

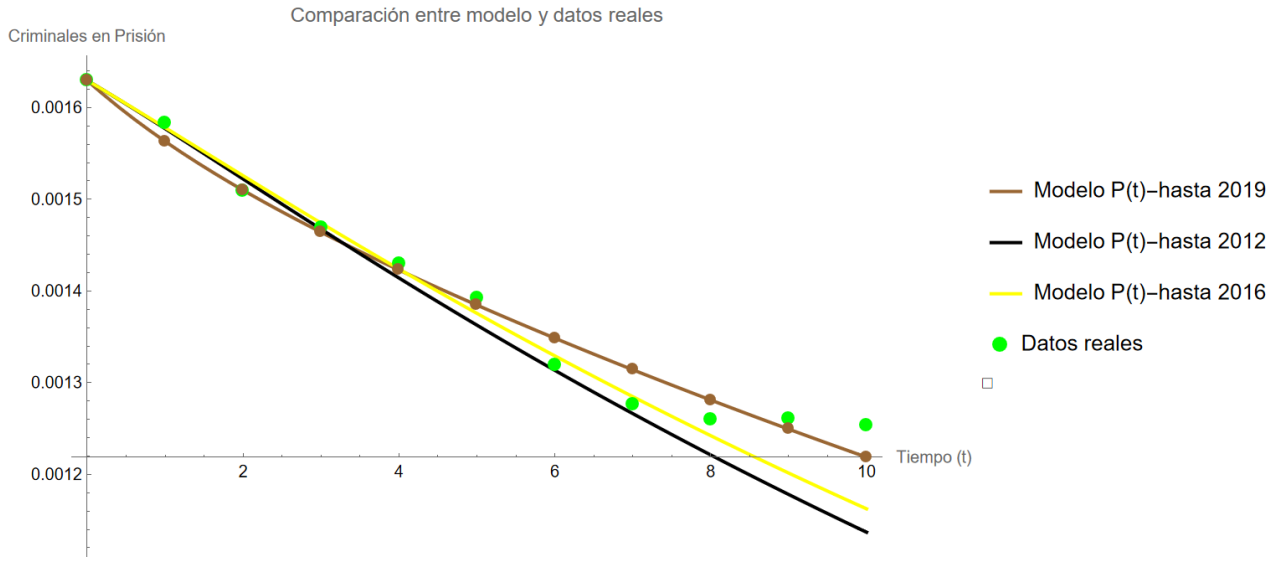

Figura 3.10: Todos los ajustes

Vemos que conforme más datos utilizamos, la curva se acerca más a la curva imaginaria de los datos reales y el modelo es mejor y tiene mejor capacidad predictiva.

Número Básico de Reproducción

Teniendo en cuenta 3.3, el número de reproducción básico es

$$\mathcal{R}_0 = 0{,}998.$$

Dado que es menor que 1, se concluye que, si las cosas permanecen igual y los parámetros se mantienen invariantes en el tiempo, la criminalidad se extinguirá en el futuro.

Sin embargo, $\mathcal{R}_0$ está muy cerca del umbral 1, por lo que cualquier variación de los parámetros puede hacer que lo supere y que la criminalidad se vuelva endémica.

Deben establecerse políticas de control para asegurar que $\mathcal{R}_0$ no crezca y, mejor aún, que se reduzca. Para encontrar las mejores medidas de control, se realiza un análisis de sensibilidad[10].

3.5. Análisis de Sensibilidad

La sensibilidad predice qué parámetros tienen un alto impacto sobre $\mathcal{R}_0$. El índice de sensibilidad de un parámetro λ es

$$\Gamma_\lambda = \frac{\partial \mathcal{R}_0}{\partial \lambda} \times \lambda, \tag{3.4}$$

dado por la variación infinitesimal del umbral $\mathcal{R}_0$ respecto al parámetro, teniendo en cuenta la magnitud del parámetro. El índice identifica el parámetro clave, aunque la viabilidad y el coste también desempeñan un papel importante. En nuestro caso y según 3.3, los índices de sensibilidad son

$$\Gamma_\beta = \frac{\beta N}{a_1 + a_2 + \mu}, \quad \Gamma_{a_1} = \frac{-\beta N a_1}{(a_1 + a_2 + \mu)^2}, \quad \Gamma_{a_2} = \frac{-\beta N a_2}{(a_1 + a_2 + \mu)^2}.$$

El signo nos indica si $\mathcal{R}_0$ aumenta o disminuye con el parámetro. Por ejemplo, en nuestro caso, una alta capacidad de influencia de los infractores incrementa la criminalidad. Las intervenciones sociales para evitar este tipo de transición son de máxima importancia para lograr una sociedad libre de crimen. Por otro lado, decisiones más rápidas sobre los infractores (detenciones, juicios, etc.) ayudan a mitigar la criminalidad. Esta aceleración de los procesos judiciales debería ser tenida en cuenta por las autoridades.

Es interesante observar que el tiempo en prisión no está relacionado con $\mathcal{R}_0$, posiblemente porque asumimos en el modelo que la fuerza de influencia β es independiente del tiempo en prisión $1/r$. Si el tiempo en prisión fuera mayor, la dinámica a largo plazo del modelo, que solo depende de si $\mathcal{R}_0 \leq 1$ o $\mathcal{R}_0 > 1$, no se vería afectada. La relación entre el tiempo en prisión y la incidencia de criminalidad en España ha sido discutida en algunos textos [15].

El artículo[16] muestra que "incrementar los costes directos del crimen —ya sea aumentando el castigo o los esfuerzos de cumplimiento— no reduce necesariamente la criminalidad y puede de hecho desencadenar un aumento indirecto del crimen". Otro documento interesante en el que se puede profundizar en este hecho es lo encontramos en [17].

Por otro lado, las tendencias demográficas en el modelo que miden la diferencia entre entradas y salidas de ciudadanos también afectan a $\mathcal{R}_0$, como es bien conocido del simple modelo SIR con dinámica vital.

En España, los índices de sensibilidad son

$$\Gamma_\beta = 0{,}998, \quad \Gamma_{a_1} = -0{,}246, \quad \Gamma_{a_2} = -0{,}750.$$

Por tanto, el parámetro más importante a controlar es la fuerza de influencia, seguido por las transiciones de L a P y de L a S.

Esta situación puede varias dependiendo de cada país o la circunstancias de una población en concreto por eso es importante hacer este tipo de estudios y ajustes para intentar entender, predecir y mejorar el comportamiento, en este caso, de la

actividad delictiva de un grupo de personas. Aunque nuestro modelo propuesto es una idealización del complejo proceso de la criminalidad (se asumen cosas no del todo realistas), demuestra cómo políticas adecuadas que manipulan los parámetros en 3.3 (es decir, las transiciones entre estados) eventualmente afectan la proporción de personas activamente involucradas en actividades criminales dentro de la población.

Capítulo 4

Conclusiones

Esta sección tiene como objetivo ofrecer una breve síntesis de los contenidos abordados a lo largo de este Trabajo de Fin de Grado y si se han cumplido los objetivos previamente marcados.

4.1. Resumen y Análisis del Desarrallo del TFG

En primer lugar, se expuso el problema de estudio y se presentó la metodología adoptada para alcanzar los objetivos propuestos.

En el segundo capítulo, considerado el núcleo del trabajo, se profundiza en el papel de las ecuaciones diferenciales como herramienta para modelar dinámicas poblacionales a lo largo del tiempo. Se analiza en detalle el Modelo SIR, uno de los pilares fundamentales en el estudio del crecimiento poblacional mediante compartimentos. Sobre este modelo se basa nuestro enfoque principal: la división de la población entre quienes presentan actividad delictiva y quienes no.

En esta sección del SIR se consideró esencial presentar ejemplos prácticos que ilustraran su funcionamiento, así como las distintas estrategias para calibrar los parámetros que lo componen.

Por último, en lo que constituye la base fundamental de este trabajo, se desarrolla el capítulo 3, en el cual se plantea un modelo para describir la actividad delictiva en una población. En este modelo se consideran los parámetros relevantes, los factores que pueden inducir un aumento o una disminución de la actividad delictiva, y se enfatiza la importancia del estudio de este tipo de dinámicas sociales. Se muestra la viabilidad del modelo, así como la relevancia del Número Básico de Reproducción R_0 y distintos resultados teóricos para calcularlo.

Para validar el modelo propuesto, se utilizaron datos empíricos correspondientes a España, lo cual permitió ponerlo a prueba en un contexto real. En este proceso, se aplicaron una combinación de métodos previamente descritos en el modelo SIR: algunos parámetros fueron estimados o tomados directamente de fuentes estadísticas oficiales españolas, y los otros se calibraron mediante ajuste por mínimos cuadrados.

En este capítulo se incluyó un análisis de la capacidad predictiva del modelo, que arrojó resultados notablemente buenos y satisfactorios. Finalmente, se realizó un análisis de sensibilidad que permitió profundizar en la comprensión del Número Básico de Reproducción y de las posibles estrategias de intervención según su valor e influencia de los distintos índices. Se reflexiona además sobre qué aspectos deben considerarse cuidadosamente al modelar fenómenos complejos como la criminalidad.

4.2. Conclusiones Finales

Dado los objetivos previamente establecidos en la introducción de este trabajo, se ha realizado un esfuerzo significativo mediante el análisis y la síntesis de información procedente de diversas fuentes con el fin de ofrecer al lector una visión clara de los fundamentos teóricos empleados, especialmente dentro del ámbito de las matemáticas aplicadas y de las ecuaciones diferenciales. Se buscó que, incluso sin un conocimiento técnico previo, el lector pudiera comprender la importancia de los modelos compartimentales, en particular el modelo SIR, y cómo estos pueden aplicarse al análisis de fenómenos sociales, como la evolución de la actividad delictiva en una población.

Uno de los objetivos clave fue mostrar que este tipo de modelos, a pesar de su aparente simplicidad, pueden ofrecer resultados relevantes y útiles en contextos complejos. En este sentido, se considera fundamental comprender qué factores influyen en el crecimiento o disminución del número de infractores, así como identificar patrones que, aunque puedan parecer intuitivos, tienen implicaciones teóricas importantes. Por ejemplo, se evidenció cómo un mayor tiempo de permanencia en prisión, contrario a lo que podríamos pensar, no contribuiría a la reducción de las tasas de reincidencia.

Asimismo, a través de diferentes ejemplos desarrollados a lo largo del trabajo, se han simplificado ciertos elementos técnicos con el objetivo de facilitar su comprensión, sin sacrificar el rigor necesario para aplicar estos modelos a la realidad. Se ha tenido especial cuidado en adaptar la formulación matemática al nivel requerido, de modo que el lector pueda seguir el razonamiento sin necesidad de una formación especializada previa.

En definitiva, este trabajo pretende ser una invitación a seguir explorando el potencial de los modelos matemáticos en el estudio de fenómenos sociales. Al incorporar nuevos factores, parámetros o hipótesis, estos modelos pueden enriquecerse y ajustarse mejor a diferentes contextos, ya se trate del análisis del crimen o de cualquier otro fenómeno de interés.

Bibliografía

[1] *Conducta criminal: análisis de sus causas*, Psicología Científica (s.f.), [en línea] Disponible en: https://psicologiacientifica.com/conducta-criminal-analisis-de-sus-causas

[2] *Factores biológicos en la conducta criminal: teorías y estudios*, Uninotas (s.f.), [en línea] Disponible en: https://www.uninotas.net/factores-biologicos-en-la-conducta-criminal-teorias-y-estudios/

[3] M. A. Lázaro Lorca, *Trabajo Fin de Grado*, Universidad Pontificia Comillas (2019), [en línea]. Disponible en: https://repositorio.comillas.edu/xmlui/bitstream/handle/11531/27439/TFG-%20LAzaro%20Lorca%2c%20MarAa.pdf

[4] J. Calatayud, M. Jornet y J. Mateu, *A dynamical mathematical model for crime evolution based on a compartmental system with interactions.*

[5] F. Brauer, *Chapter 2. Compartmental Models in Epidemiology*, pp. 8–27.

[6] Anonymous, *Influenza in a boarding school*, British Medical Journal, Vol. 1, p. 587, 1978. Consultado en: http://www.math.unm.edu/~sulsky/mathcamp/Anon_InfluenzaBoardingSchool_BMJ_1978.pdf

[7] J. Sooknanan y D. M. Comissiong, *When behaviour turns contagious: The use of deterministic epidemiological models in modeling social contagion phenomena*, Int. J. Dyn. Cont. 5(4) (2017), pp. 1046–1050.

[8] F. Brauer, *Compartmental models in epidemiology*, en F. Brauer, P. van den Driessche y J. Wu (eds.), *Mathematical Epidemiology*, Springer, Berlin–Heidelberg, 2008, pp. 19–79.

[9] T. Caraballo and X. Han, *Applied Nonautonomous and Random Dynamical Systems: Applied Dynamical Systems*, Springer, New York, 2017.

[10] P. Van den Driessche, "Reproduction numbers of infectious disease models," *Infectious Disease Modelling*, vol. 2, no. 3, 2017, pp. 288–303.

[11] P. Van den Driessche and J. Watmough, "Further notes on the basic reproduction number," in *Mathematical Epidemiology*, F. Brauer, P. van den Driessche, and J. Wu, Eds., Springer, Berlin, Heidelberg, 2008, pp. 159–178.

[12] G. Teschl, *Ordinary Differential Equations and Dynamical Systems*, Graduate Studies in Mathematics, vol. 140, American Mathematical Society, Providence, 2012.

[13] H.H. Weiss, *The SIR model and the foundations of public health*, Materials Matemàtics, vol. 2013(3), 2013, pp. 1–17.

[14] F.J. Santonja, E. Sánchez, M. Rubio y J.L. Morera, *Alcohol consumption in Spain and its economic cost: A mathematical modeling approach*, Mathematical and Computer Modelling, vol. 52(7–8), 2010, pp. 999–1003.

[15] D. García-Magna, *El recurso excesivo al derecho penal en España. Realidad y alternativas (The excessive use of criminal law in Spain. Reality and alternatives)*, Política Criminal, vol. 14(27), 2019, pp. 98–121.

[16] J. Nussim and A. D. Tabbach, *Deterrence and avoidance*, International Review of Law and Economics, vol. 29(4), 2009, pp. 314–323.

[17] I. Ehrlich, *The deterrent effect of criminal law enforcement*, Journal of Legal Studies, vol. 1, 1972, pp. 259–276.

Apéndice

Código

Cálculo Parámetros Brote Inglaterra

```
modelo = ParametricNDSolveValue[
  {s'[t] == -beta*s[t]*i[t], i'[t] == beta*s[t]*i[t] - alpha*i[t],
   s[0] == 760, i[0] == 3}, {s, i}, {t, 0, 13}, {beta, alpha}];

modelo2[beta_?NumericQ, alpha_?NumericQ] := modelo[beta, alpha]

datos = {3, 8, 28, 75, 221, 291, 255, 235, 190, 125, 70, 28, 12, 5};

tiempos = Range[0, 13];

error[beta_?NumericQ, alpha_?NumericQ] :=
  Sum[(modelo2[beta, alpha][[2]][t] - datos[[t + 1]])^2, {t, 0, 13}]

NMinimize[{error[beta, alpha], 0 <= beta, 0 <= alpha}, {beta, alpha}]
```

Gráfica Brote de Inglaterra

```
puntosDatos = ListPlot[Transpose[{tiempos, datos}],
  PlotStyle -> {Red, PointSize[Medium]}, PlotLegends -> {"Datos reales"}];
```

```
curvaModelo = Plot[modelo2[0.00221909, 0.450941][[2]][t], {t, 0, 13},
  PlotStyle -> Blue, PlotLegends -> {"Modelo i(t)"}];

Show[curvaModelo, puntosDatos, PlotLabel -> "Comparación entre modelo y
datos reales",
  AxesLabel -> {"Tiempo (t)", "Infectados"}, ImageSize -> Large]
```

La Plaga de Eyam-Ajuste Teórico

```
modelo = ParametricNDSolveValue[{s'[t] == -beta*s[t]*i[t],
    i'[t] == beta*s[t]*i[t] - alpha*i[t], s[0] == 254, i[0] == 7},
    {s, i}, {t, 0, 5.17}, {beta, alpha}];

modelo2[beta_?NumericQ, alpha_?NumericQ] := modelo[beta, alpha];

datosInfectados = {7, 14, 22, 29, 21, 8, 8, 0};
datosSusceptibles = {254, 235, 201, 153, 103, 100, 83, 83};
tiempos = {0, 1.5, 2.03, 2.53, 3.07, 3.57, 4.1, 5.17};

datosSusceptiblesPareados = Transpose[{tiempos, datosSusceptibles}];
datosInfectadosPareados = Transpose[{tiempos, datosInfectados}];

puntosSusceptibles = ListPlot[datosSusceptiblesPareados,
    PlotStyle -> {Red, PointSize[Medium]},
    PlotLabels -> {"Datos reales"}];

puntosInfectados = ListPlot[datosInfectadosPareados,
    PlotStyle -> {Red, PointSize[Medium]},
    PlotLabels -> {"Datos reales"}];

puntosDatos = ListPlot[Transpose[{datosSusceptibles, datosInfectados}],
    PlotStyle -> {Red, PointSize[Medium]},
    PlotLabels -> {"Datos reales"}];

curvaSusceptibles = Plot[modelo2[0.0178, 2.73][[1]][t], {t, 0, 5.17},
    PlotStyle -> Blue,
    PlotLabels -> {"Modelo S(t)"}];

curvaInfectados = Plot[modelo2[0.0178, 2.73][[2]][t], {t, 0, 5.17},
    PlotStyle -> Blue,
    PlotLabels -> {"Modelo I(t)"}];

GraficaConjunta = ParametricPlot[
    {modelo2[0.0178, 2.73][[1]][t], modelo2[0.0178, 2.73][[2]][t]},
    {t, 0, 5.17}, AxesLabel -> {"S(t)", "I(t)"},
```

```
    PlotLabels -> "Curva (S, I)",
    PlotStyle -> Blue, AspectRatio -> 0.5];

Show[curvaSusceptibles, puntosSusceptibles,
    PlotLabel -> "Comparación entre datos y modelo S(t)",
    AxesLabel -> {"Tiempo (t)", "Susceptibles"}, ImageSize -> Large];

Show[curvaInfectados, puntosInfectados,
    PlotLabel -> "Comparación entre datos y modelo I(t)",
    AxesLabel -> {"Tiempo (t)", "Infectados"}, ImageSize -> Large];

Show[GraficaConjunta, puntosDatos,
    PlotLabel -> "Comparación entre modelo y datos reales",
    AxesLabel -> {"Susceptibles", "Infectados"},
    ImageSize -> Large, PlotRange -> All, AspectRatio -> 0.8];
```

Ajuste de parámetros por mínimos cuadrados Plaga de Eyam

```
modelo = ParametricNDSolveValue[
  {s'[t] == -beta*s[t]*i[t],
   i'[t] == beta*s[t]*i[t] - alpha*i[t],
   s[0] == 254,
   i[0] == 7},
  {s, i}, {t, 0, 5.17}, {beta, alpha}];

modelo2[beta_?NumericQ, alpha_?NumericQ] := modelo[beta, alpha];

datos = {7, 14, 22, 29, 21, 8, 8, 0};
tiempos = {0, 1.5, 2.03, 2.53, 3.07, 3.57, 4.1, 5.17};

error[beta_?NumericQ, alpha_?NumericQ] :=
  Sum[(modelo2[beta, alpha][[2]][t] - datos[[t + 1]])^2, {t, 0, 7}];

NMinimize[{error[beta, alpha], 0 <= beta, 0 <= alpha}, {beta, alpha}]
```

Ajuste de parámetros por mínimos cuadrados Plaga de Eyam

```
puntosDatos = ListPlot[Transpose[{tiempos, datos}],
    PlotStyle -> {Red, PointSize[Medium]},
    PlotLegends -> {"Datos reales"}];

curvaModelo = Plot[modelo2[0.0097074, 1.5569][[2]][t],
    {t, 0, 5.17}, PlotStyle -> Blue,
    PlotLegends -> {"Modelo i(t)"}];

Show[curvaModelo, puntosDatos,
```

```
    PlotLabel -> "Comparación entre modelo y datos reales",
    AxesLabel -> {"Tiempo (t)", "Infectados"},
    ImageSize -> Large, PlotRange -> All]
```

Ajuste de parámetros por mínimos cuadrados Crimen España

```
modelo = ParametricNDSolveValue[
  {
    s'[t] == 1/82 - beta*s[t]*l[t] + (2/3)*p[t] + (12/7)*l[t] - (1/82)*s[t],
    l'[t] == beta*s[t]*l[t] - (12/7)*l[t] - (12/2.3)*l[t] - (1/82)*l[t],
    p'[t] == (12/2.3)*l[t] - (2/3)*p[t] - (1/82)*p[t],
    l[0] == 1 - 76079/46686994 - S0,
    p[0] == 76079/46686994,
    s[0] == S0
  },
  {s, l, p},
  {t, 0, 10},
  {beta, S0}
];

modelo2[beta_?NumericQ, S0_?NumericQ] := modelo[beta, S0];

datos = {
  76079/46686994, 73929/46686994, 70472/46686994, 68597/46686994,
  66765/46686994, 65017/46686994, 61614/46686994, 59589/46686994,
  58814/46686994, 58883/46686994, 58517/46686994
};

tiempos = Range[0, 10];

error[beta_?NumericQ, S0_?NumericQ] :=
  Sum[(modelo2[beta, S0][[3]][t] - datos[[t + 1]])^2, {t, 0, 10}];

NMinimize[{error[beta, S0], 0 <= beta, 0 <= S0 < 1}, {beta, S0}]
```

Graficado Crimen España 2009-2019

```
puntosDatos = ListPlot[Transpose[{tiempos, datos}],
    PlotStyle -> {Red, PointSize[Tiny]},
    PlotMarkers -> Automatic,
    PlotLabels -> {"Datos reales"}];

curvaModeloConPuntos = Plot[modelo2[6.92912, 0.998173][[3]][t],
    {t, 0, 10}, PlotStyle -> Blue,
    PlotLabels -> {"Modelo P(t)"},
    Epilog -> {Green, PointSize[Medium],
```

```
      Table[Point[{ti, modelo2[6.92912, 0.998173][[3]][ti]}], {ti, 0, 10}]},
    PlotLabels -> DatosReales];

Show[curvaModeloConPuntos, puntosDatos,
    PlotLabel -> "Comparación entre modelo y datos reales",
    AxesLabel -> {"Tiempo (t)", "Criminales en Prisión"},
    ImageSize -> Large, PlotRange -> All]
```

Resultados Teóricos

Teorema 4. *[11][Teorema 1]: El CFE es localmente asintóticamente estable si* $\mathcal{R}_0 < 1$*, pero inestable si* $\mathcal{R}_0 > 1$*.*

Demostración. Algunos comentarios se deben hacer aquí. Primero, en general, el carácter del CFE es desconocido cuando $\mathcal{R}_0 = 1$. Segundo, cuando $\mathcal{R}_0 < 1$, la estabilidad asintótica es en principio local. Para la estabilidad global, existe un resultado en [11][Teorema 2] que no se aplica a nuestro sistema 3.1. Y tercero, cuando $\mathcal{R}_0 > 1$, no hay más información que la inestabilidad.

Recordemos que, dado un dominio de definición del sistema, un punto de equilibrio es globalmente asintóticamente estable si es estable y un atractor global. En lo que sigue, probamos rigurosamente la estabilidad asintótica global del CFE del sistema 3.1 cuando $\mathcal{R}_0 \leq 1$, utilizando una función de Lyapunov adecuada. Además, se prueba la estabilidad asintótica global del equilibrio endémico del crimen (CEE) del sistema 3.1 cuando $\mathcal{R}_0 > 1$ (suponiendo que la órbita no sea simplemente {CFE}), aplicando teoría específica para sistemas planos.

Para ello, en lugar de usar la teoría general sobre el número básico de reproducción, nos enfocamos en nuestro sistema particular 3.1 y usamos resultados clásicos de la teoría de sistemas dinámicos. Para más fundamentos sobre sistemas dinámicos, véase [12].

□

Teorema 5. *Si* $\mathcal{R}_0 \leq 1$*, entonces el CFE es globalmente asintóticamente estable para el sistema 3.1 en* $[0, N]^3$*.*

Si $\mathcal{R}_0 > 1$, entonces el CEE es *globalmente asintóticamente estable* para el sistema 3.1 en $[0, N]^3 \setminus \{(N, 0, 0)\}$.

$$[0, N]^3 = \left\{(S, L, P) \in \mathbb{R}^3 \;\middle|\; 0 \leq S \leq N,\ 0 \leq L \leq N,\ 0 \leq P \leq N\right\}$$

Demostración. Los puntos de equilibrio del sistema 3.1 son los siguientes:

$$\text{CFE} = (N, 0, 0),$$

y cuando $\mathcal{R}_0 > 1$,

$$\text{CEE} = \left(\frac{a_1 + a_2 + \mu}{\beta}, \frac{(N - \frac{a_1+a_2+\mu}{\beta})(\mu + r)}{a_2 + \mu + r}, a_2 \cdot \frac{N - \frac{a_1+a_2+\mu}{\beta}}{a_2 + \mu + r} \right).$$

No hay más puntos de equilibrio. Estos se obtienen igualando las tres ecuaciones del sistema 3.1 a cero, tomando en cuenta la ley de conservación 3.2, es decir, $N = \lambda/\mu$.

Supongamos que $\mathcal{R}_0 \leq 1$. Consideramos el sistema dinámico plano:

$$\begin{aligned} \frac{dS}{dt} &= -\beta SL + r(N - S - L) + a_1 L - \mu S, \\ \frac{dL}{dt} &= \beta SL - a_1 L - a_2 L - \mu L, \end{aligned}$$

el cual es equivalente al sistema 3.1 al establecer $P = N - S - L$. La función $V(S, L) = \frac{1}{2}(S, L)$ en $[0, N] \times [0, N]$ es una función de Lyapunov estricta para el punto fijo $(N, 0)$ del sistema plano. De hecho, primero, $V(N, 0) = 0$ y $V(S, L) > 0$ para $(S, L) \neq (N, 0)$. Segundo, $V(S, L) = SL$, y su derivada respecto al tiempo satisface:

$$\dot{V} = L[\dot{S} + S\dot{L}] = L[-\beta SL + r(N - S - L) + a_1 L - \mu S + \beta SL - (a_1 + a_2 + \mu)L]$$

$$\dot{V} = L[r(N - S - L) - \mu S - (a_2 + \mu)L] < 0$$

para $L \neq 0$, ya que $r > 0$. Por lo tanto, el punto $(N, 0, 0)$ es localmente asintóticamente estable para el sistema completo. Además, el conjunto $\{(S, L, P) \in [0, N]^3 : P = 0\}$ es positivamente invariante, y $(N, 0, 0)$ es globalmente asintóticamente estable en $[0, N] \times [0, N]$. Con eso, hemos terminado.

Supongamos ahora que $\mathcal{R}_0 > 1$. Consideramos el sistema dinámico plano:

$$\begin{aligned} \frac{dL}{dt} &= \beta(N - L - P)L - a_1 L - a_2 L - \mu L, \\ \frac{dP}{dt} &= a_2 L - rP - \mu P, \end{aligned}$$

el cual es equivalente al sistema 3.1 al establecer $S = N - L - P$. Definimos:

$$f(L, P) = (f_1(L, P), f_2(L, P)) = (\beta(N - L - P)L - a_1 L - a_2 L - \mu L,\ a_2 L - rP - \mu P).$$

El Jacobiano de f evaluado en el CEE tiene autovalores con partes reales negativas (verificado simbólicamente), por lo que el CEE es localmente asintóticamente estable. Dado $(v, L, P) \in [0, N]^3$, tenemos:

$$\frac{\partial f_1}{\partial P}(L,P) = -\beta L, \quad \frac{\partial f_2}{\partial L}(L,P) = a_2, \quad \Rightarrow \quad \frac{\partial f_1}{\partial P}\cdot\frac{\partial f_2}{\partial L} - \frac{\partial f_1}{\partial L}\cdot\frac{\partial f_2}{\partial P} = \beta a_2 \cdot \frac{r+\mu}{L} > 0.$$

Por el criterio de Bendixson-Dulac, no existen trayectorias periódicas no constantes. Por tanto, para este sistema plano, cualquier órbita que no sea $\{(N,0)\}$ tiene como límite un punto de equilibrio. Por lo tanto, el CEE es el límite de una órbita no constante.

Dado $\epsilon > 0$, sea $(L_\epsilon(t), P_\epsilon(t))$ una solución del sistema plano con condiciones iniciales $L(0) = \epsilon,\ P(0) = 0$. Como $\frac{dL}{dt} > 0$ cuando $L \to 0^+$ y $\frac{dP}{dt} > 0$ cuando $P = 0$, entonces $f_1(\epsilon, 0) > 0$ y $f_2(\epsilon, 0) > 0$. Por tanto, la solución crece en ambas variables y converge hacia el CEE.

$\square$