

Minería de Datos en el Mercado de Coches de Segunda Mano en Marruecos

Análisis del Dataset MUCars-2024

Saraí Torres
José Ramón Mena Pérez
Salvador Naharros Pérez
Grupo 6 · Minería de Datos · Mayo 2026

Índice

Resumen	1
Introducción	2
Objetivos	3
Metodología.....	3
Resultados	4
Preprocesamiento de datos e imputación	4
Análisis no supervisado.....	6
Análisis supervisado de clasificación	8
Análisis supervisado de regresión	10
Conclusiones	16
Anexos	17
Anexo I. Librerías y ficheros	17
Anexo II. Descripción del dataset y análisis exploratorio	18
Anexo III. Detalles de modelos de clasificación.....	24
Anexo IV. Diagnósticos, árbol CART y ALE/LIME	28
Referencias	33

Resumen

El presente trabajo aplica técnicas de minería de datos sobre el dataset **MUCars-2024**, formado por 71.369 anuncios de coches de segunda mano publicados en Marruecos y recopilados mediante *web scraping*. Tras un preprocesamiento exhaustivo —corrección de errores del *scraper*, transformación de variables e

imputación de valores faltantes mediante KNN— se obtiene una base lista para el análisis. El análisis exploratorio y el PCA revelan que la antigüedad, el kilometraje y la potencia fiscal son los principales ejes de variabilidad del precio, con los extras de equipamiento formando un eje secundario ortogonal. Se comparan cinco modelos de clasificación para predecir si un vehículo ha tenido un único propietario, y tres modelos de regresión para estimar el precio. En clasificación, la regresión logística ofrece el mejor balance entre rendimiento e interpretabilidad. En regresión, el *Random Forest* supera claramente al modelo lineal y al árbol CART en todas las métricas de error. Los resultados confirman que la antigüedad, el tipo de cambio y el kilometraje son los determinantes fundamentales del precio en este mercado.

Introducción

El mercado de vehículos de segunda mano en Marruecos ocupa un lugar central en la economía del país. Las elevadas tasas arancelarias sobre la importación de vehículos nuevos y una flota media de considerable antigüedad hacen que la mayoría de las transacciones de movilidad privada se realicen en el mercado de ocasión, generando además empleo en sectores como la venta, el mantenimiento y la financiación (Tabarnoust et al. 2025). En este contexto, la fijación del precio de un vehículo usado es una tarea compleja: el vendedor particular carece de referencias objetivas de mercado, el comprador no puede verificar fácilmente si el precio publicado es razonable, y la información sobre el estado real del vehículo es asimétrica.

El dataset empleado, **MUCars-2024** (Tabarnoust et al. 2025), fue recopilado mediante *web scraping* automatizado de las principales plataformas marroquíes de compraventa de vehículos. Contiene **71.369 anuncios** con **15 variables** que cubren las características técnicas del vehículo (antigüedad, kilometraje, tipo de combustible, potencia fiscal, número de puertas, tipo de cambio), su estado de conservación, la procedencia geográfica, el historial de propiedad (*First.Owner*), la dotación de equipamiento y el precio de venta en dirhams marroquíes (MAD). El proceso de *scraping* introdujo diversas incidencias —valores en francés o árabe, kilometrajes codificados como intervalos de texto, precios erróneos capturados como números de teléfono— que requieren un preprocesamiento específico antes de cualquier análisis.

Este trabajo se estructura como sigue: la Sección 3 describe la metodología y el *software* empleado; la Sección 4 presenta los resultados organizados en cuatro bloques —preprocesamiento e imputación, análisis no supervisado, modelos de clasificación y modelos de regresión—; la Sección 5 recoge las conclusiones del estudio.

Objetivos

El objetivo principal de este trabajo es **evaluar y comparar distintas técnicas de minería de datos supervisadas y no supervisadas** para extraer conocimiento útil del mercado marroquí de vehículos de segunda mano. En particular, se persiguen dos objetivos predictivos:

1. **Predicción del precio de venta** (Price, variable continua): construir y comparar modelos capaces de estimar el precio de mercado de un vehículo a partir de sus características técnicas y estado. Este problema responde directamente a la incertidumbre a la que se enfrenta cualquier comprador al evaluar si el precio de un anuncio es justo: disponer de un modelo predictivo permite comparar el precio publicado con el valor esperado según las condiciones del vehículo, detectando sobreprecios o gangas de forma objetiva.
 2. **Clasificación del primer propietario** (First.Owner, variable binaria): identificar qué características distinguen los vehículos que han tenido un único dueño, información que influye directamente en la percepción de valor y el precio que el mercado está dispuesto a pagar.
-

Metodología

Todo el análisis se ha realizado en **R** (R Core Team 2024) con una metodología organizada en cinco etapas secuenciales:

1. **Preprocesamiento y limpieza:** corrección de errores específicos del *scraper*, transformación de variables (año → antigüedad, intervalos de kilometraje → punto medio, texto libre de equipamiento → contadores numéricos), eliminación de duplicados y de filas con exceso de valores faltantes.
2. **Imputación KNN:** tratamiento de valores faltantes en las variables predictoras mediante kNN del paquete VIM (Kowarik y Templ 2016) con $k = 5$. Las variables objetivo (Price y First.Owner) no se imputan.
3. **Análisis exploratorio (EDA):** distribuciones univariantes con comparación antes/después de la imputación para verificar que KNN no distorsiona las distribuciones originales.
4. **Análisis no supervisado (PCA):** reducción de dimensionalidad con FactoMineR (Lê et al. 2008) y visualización con factoextra (Kassambara y Mundt 2020) sobre el subconjunto de observaciones con precio conocido. Condition se incluye como variable suplementaria cualitativa.

5. **Modelos supervisados:** regresión (LM con selección *backward* por AIC mediante `step()`, CART con regla 1-SE (Breiman et al. 1984), *Random Forest* (Breiman 2001)) y clasificación (regresión logística, CART, *Random Forest*, SVM lineal y Naive Bayes) gestionados con `caret` (Kuhn 2008). La selección de variables tanto en el LM como en la regresión logística se realiza con `step(direction="backward")` por AIC. La evaluación se realiza mediante *hold-out* 75/25 estratificado. La interpretabilidad del *Random Forest* se aborda con ALE y LIME mediante el paquete `iml` (Molnar et al. 2018), y la curva REC con `auditor` (Gosiewska y Biecek 2019). Las visualizaciones se han generado con `ggplot2` (Wickham 2016).

Los métodos y técnicas aplicados siguen los contenidos de la asignatura (Debón Aucejo 2025). El desarrollo del código ha contado con el apoyo de la herramienta de asistencia Claude Code (Anthropic 2025).

Resultados

Preprocesamiento de datos e imputación

Descripción del dataset

El dataset MUCars-2024 contiene **71.369 observaciones** y **15 variables**. La descripción detallada de cada variable, su tipo y rol en el análisis se recoge en el Anexo II.

Limpieza y preprocesamiento

El dataset original presentaba diversas incidencias derivadas del *web scraping*: valores en francés, kilometrajes codificados como intervalos de texto, precios capturados como números de teléfono, ciudades en árabe y códigos numéricos de marca.

Carga del dataset

Corrección manual de errores de campo

El proceso de *web scraping* introdujo en un caso un valor de kilometraje ("35 000 - 39 999") en el campo `Fuel`. Se corrige antes de cualquier transformación.

Transformaciones de variables numéricas

Se calculó la antigüedad ($\text{Age} = 2026 - \text{Year}$), el punto medio del intervalo de kilometraje y la potencia fiscal como entero.

Limpieza de variables categóricas

Corrección de errores en Price y eliminación de duplicados

Los precios inferiores a 5.000 MAD y superiores a 1.500.000 MAD son errores del *scraper* y se marcan como NA, preservando la información restante de la observación para los modelos de clasificación, donde Price no actúa como predictor.

Extracción de equipamiento y filtrado de filas con exceso de NAs

La variable Equipment se transformó en dos contadores: n_extras_seguridad (0–4) y n_extras_tecnologia (0–12). Se eliminaron las filas con 3 o más valores faltantes.

Resumen del proceso de limpieza

Tabla 2. Reducción del dataset a lo largo de la limpieza.

Etapas	Filas
Dataset original	71369
– Duplicados exactos	-1486
– Filas con 3 o más NAs	-5033
= Dataset limpio	64850

Tabla 3. Valores faltantes pendientes de imputación.

Variable	NAs	Porcentaje
Price	15156	23.4 %
First.Owner	5475	8.4 %
Origin	4125	6.4 %
Number.of.Doors	3491	5.4 %
Condition	707	1.1 %
Sector	130	0.2 %
Fiscal_Power_num	116	0.2 %

Nota sobre Price: su porcentaje de valores faltantes supera el umbral habitual del 20% a partir del cual se recomienda reconsiderar la inclusión de la variable. Sin embargo, dado que Price es la variable objetivo principal del análisis de regresión —y su ausencia es en su mayoría atribuible a errores del *scraper*, no a un patrón sistemático—, se conserva íntegramente y no se imputa. Las observaciones con Price ausente participarán en la tarea de clasificación pero quedarán excluidas del modelado de regresión.

Imputación de valores faltantes


Se utilizó imputación por vecinos más cercanos con la función kNN del paquete VIM (Kowarik y Templ 2016), $k = 5$. Las variables Price y First.Owner no se imputan al ser variables objetivo. La imputación se realiza de forma independiente para cada variable, usando siempre el dataset limpio original como base.


El análisis exploratorio de las distribuciones antes y después de la imputación se recoge en el Anexo II, donde se puede comprobar que KNN no distorsiona las distribuciones originales.

Análisis no supervisado

Análisis de Componentes Principales (PCA)

Para explorar la estructura de correlaciones entre las variables numéricas se aplica un PCA con FactoMineR (Lê et al. 2008). El análisis se restringe al subconjunto de observaciones con Price conocido (sin NAs), de modo que las seis variables numéricas entran completas. La variable Condition se incorpora como **variable suplementaria cualitativa** para interpretar en qué zona del espacio factorial se ubican los distintos estados del vehículo sin que influya en el cálculo de las componentes.





Las dos primeras componentes explican conjuntamente el 60.4 % de la varianza total, próximo al 60 %, lo que confirma que el espacio bidimensional captura la estructura esencial del dataset. El criterio de Kaiser indica retener PC1 y PC2 al superar ambas la varianza media por componente.

En el círculo de correlaciones se aprecian los siguientes patrones:

- **n_extras_seguridad y n_extras_tecnologia están extremadamente correlacionados positivamente** (sus vectores son casi paralelos y apuntan en la misma dirección en PC2). Esto tiene pleno sentido: los vehículos modernos incorporan simultáneamente más elementos de seguridad (airbags, ABS, ESP) y más dotación tecnológica (GPS, cámara trasera, Bluetooth), por lo que ambos contadores evolucionan conjuntamente. Para los análisis supervisados posteriores se unificarán en una única variable `n_extras_total`, reduciendo la redundancia.

- **Age y Mileage_mid se sitúan en el extremo opuesto a Price** a lo largo de PC1: a mayor antigüedad y kilometraje, menor precio. PC1 puede interpretarse como un **eje de depreciación**.
- **Fiscal_Power_num** contribuye moderadamente a ambas componentes, con un vector casi perpendicular al grupo Age/Mileage_mid/Price. Al igual que los extras de equipamiento, se posiciona en una zona intermedia del plano factorial, indicando que la potencia fiscal tiene una asociación con el precio independiente del desgaste del vehículo.

La variable suplementaria Condition permite observar que las categorías de mejor estado (*Excellent*, *New*) se proyectan hacia la zona de Price elevado, mientras que *Fair* y *Good* se asocian a mayores valores de Age y Mileage_mid.

Análisis supervisado de clasificación

La clasificación del primer propietario (*First.Owner*) permite identificar qué características del vehículo distinguen los coches que han tenido un único dueño. Se comparan cinco modelos: regresión logística con selección *backward* por AIC, árbol CART, *Random Forest*, SVM lineal y Naive Bayes. La evaluación se realiza mediante *hold-out* 75/25 estratificado y validación cruzada interna de 5 *folds*.


Las variables *BrandModel*, *Location*, *Sector* y *Origin* se excluyen de todos los modelos supervisados por alta cardinalidad (superan el límite operativo de *Random Forest* de 53 niveles) y ausencia de efecto generalizable. Price se excluye al ser objetivo del análisis de regresión.

Comparación de modelos


Tabla 4. Comparacion de modelos de clasificacion — *First.Owner* (test).

Modelo	Accuracy	Precision	Recall	F1	AUC
Reg. logistica	0.7324	0.6752	0.6426	0.6585	0.7884
Arbol CART	0.7383	0.7100	0.5884	0.6435	0.7464
Random Forest	0.7523	0.7154	0.6358	0.6733	0.8069
SVM lineal	0.7335	0.6754	0.6471	0.6609	0.7882
Naive Bayes	0.7289	0.6615	0.6649	0.6632	0.7864

Matriz de confusion — Regresion logistica



Curvas ROC



Conclusión de clasificación

Los cinco modelos presentan métricas de *accuracy* similares entre sí, lo que refleja la dificultad inherente del problema: las características disponibles en el anuncio

tienen un poder discriminante limitado sobre el historial de propiedad. El *Random Forest* obtiene ligeramente mejores AUC y F1, pero la diferencia respecto a la regresión logística es marginal. **Se opta por la regresión logística como modelo definitivo** por su mayor interpretabilidad: los coeficientes permiten cuantificar directamente el efecto de cada variable sobre la probabilidad de ser primer propietario, lo cual tiene valor explicativo tanto en el contexto del trabajo como en una aplicación real. Los odds ratios muestran que los vehículos más recientes, con menos kilometraje y en mejor estado de conservación tienen mayor probabilidad de ser primer propietario, lo que es coherente con el comportamiento del mercado.

Tabla 4b. Odds ratios — Regresión logística (First.Owner).

	Odds Ratio
(Intercept)	3.0366
Age	0.8970
Mileage_mid	1.0000
Fiscal_Power_num	1.0329
Number.of.Doors5	0.5893
n_extras_total	1.0087
GearboxManual	0.7809
FuelElectric	0.8160
FuelHybrid	1.4656
FuelLPG	0.6798
FuelPetrol	0.8521
ConditionExcellent	2.1632
ConditionFair	1.3683
ConditionFor Parts	1.7221
ConditionGood	1.0958
ConditionNew	3.7239
ConditionVery Good	1.5067

Análisis supervisado de regresión

El objetivo es predecir el precio de venta (Price) a partir de las características del vehículo. El análisis se restringe exclusivamente a las observaciones con Price conocido; las filas con Price ausente se han eliminado antes del modelado.

Las variables BrandModel, Location, Sector y Origin se excluyen de todos los modelos supervisados: las tres primeras presentan una cardinalidad que supera el límite operativo de *Random Forest* (máximo 53 niveles), y Origin se excluye por

decisión del grupo al considerar que su efecto queda recogido por otras variables. `First.Owner` se excluye al ser el objetivo de la tarea de clasificación. Se comparan tres modelos: regresión lineal múltiple (*baseline* interpretable), árbol CART podado con la regla 1-SE (Breiman et al. 1984), y *Random Forest* (Breiman 2001).

Preparación de variables

Partición train / test

Métricas de evaluación

Modelo 1: Regresión lineal múltiple

La regresión lineal actúa como *baseline* interpretable. Los precios de vehículos usados siguen distribuciones marcadamente asimétricas y de tipo log-normal, por lo que se modela **log(Price)** como variable respuesta en lugar de Price directamente: esta transformación estabiliza la varianza de los residuos, corrige la asimetría de los errores y eleva sustancialmente el poder explicativo del modelo. Las predicciones finales se obtienen aplicando `exp()` sobre la salida del modelo, recuperando así la escala original en dirhams (MAD). Se ajusta el modelo completo sobre `log(Price)` y se aplica selección *backward* por AIC mediante `step()`, eliminando iterativamente los términos que no mejoran el criterio de información.

El diagnóstico de residuos (QQ-plot) se recoge en el Anexo IV.

Modelo 2: Árbol de regresión CART

Se construye el árbol completo y se poda con la regla 1-SE de Breiman et al. (1984). El árbol podado se presenta en el Anexo IV.

Modelo 3: Random Forest

El *Random Forest* construye 250 árboles con muestras aleatorias de entrenamiento. En cada división se selecciona aleatoriamente un subconjunto de `mtry = floor(p/3)` variables, configuración estándar para regresión. La agregación de múltiples árboles reduce la varianza de estimación sin necesidad de poda.


Comparación de modelos

Tabla 5. Comparación de métricas — LM ajustado sobre `log(Price)` con predicciones en MAD, CART y RF en escala original (test).

	RMSE	MAE	NMSE	NMAE
LM	86131.28	39062.01	0.4926	0.4831
CART	76724.30	38358.17	0.3909	0.4744
RF	70527.98	32530.85	0.3303	0.4023

La mejora es monótonica de LM a CART a RF en todas las métricas. La transición de la regresión lineal al árbol CART representa una reducción del RMSE del 10.9 % y del

MAE del 1.8 %, atribuible a la captura de interacciones. El salto del árbol al *Random Forest* es más pronunciado —RMSE cae un 8.1 % adicional— gracias a la reducción de varianza por agregación de 250 árboles.



```
## Preparation of a new explainer is initiated
## -> model label      : LM
## -> data             : 12422 rows 9 cols
## -> target variable  : 12422 values
## -> predict function : predict.function
## -> predicted values : No value for predict function target column.
( default )
## -> model_info       : package stats , ver. 4.5.1 , task regression
( default )
## -> predicted values : numerical, min = 9893.048 , mean = 125990.
1 , max = 913035.4
## -> residual function : difference between y and yhat ( default )
## -> residuals        : numerical, min = -618459.8 , mean = 13183.
```


```

59 , max = 1303426
## A new explainer has been created!

## Preparation of a new explainer is initiated
## -> model label      : CART
## -> data              : 12422 rows 9 cols
## -> target variable   : 12422 values
## -> predict function  : yhat.rpart will be used ( default )
## -> predicted values  : No value for predict function target column.
( default )
## -> model_info        : package rpart , ver. 4.1.24 , task regressio
n ( default )
## -> predicted values  : numerical, min = 46180.06 , mean = 138693.
9 , max = 637829.5
## -> residual function : difference between y and yhat ( default )
## -> residuals         : numerical, min = -582829.5 , mean = 479.78
7 , max = 1258820
## A new explainer has been created!

## Preparation of a new explainer is initiated
## -> model label      : RF
## -> data              : 12422 rows 9 cols
## -> target variable   : 12422 values
## -> predict function  : yhat.randomForest will be used ( default )
## -> predicted values  : No value for predict function target column.
( default )
## -> model_info        : package randomForest , ver. 4.7.1.2 , task r
egression ( default )
## -> predicted values  : numerical, min = 19547.16 , mean = 139272.
1 , max = 902659
## -> residual function : difference between y and yhat ( default )
## -> residuals         : numerical, min = -489967.9 , mean = -98.38
37 , max = 1268709
## A new explainer has been created!

```



La curva REC muestra el porcentaje acumulado de predicciones dentro de distintos márgenes de error absoluto. El *Random Forest* mantiene su curva por encima de las de LM y CART en prácticamente todos los niveles de tolerancia. El árbol CART supera al modelo lineal a partir de márgenes intermedios, donde la captura de interacciones empieza a ser relevante.

Interpretabilidad del Random Forest

Los dos gráficos de importancia miden aspectos complementarios. El **%IncMSE** (izquierda) cuantifica cuánto aumenta el error cuando se perturba una variable; el **IncNodePurity** (derecha) mide la reducción total de varianza acumulada en todos los árboles. Ambas métricas coinciden: **Age** es el predictor dominante, seguido de Gearbox, Mileage_mid, Fiscal_Power_num y Condition. Este ranking es coherente con el PCA y los coeficientes del LM. Los análisis ALE y LIME, que explican el efecto no lineal de Age y Mileage_mid y la explicación de predicciones individuales, se presentan en el Anexo IV.




Tabla 21. Importancia de variables — Random Forest (Price).

	%IncMSE	IncNodePurity
Age	92.12	1.276158e+14
Fiscal_Power_num	75.71	6.452828e+13
Gearbox	73.88	9.825214e+13
Fuel	48.69	1.627974e+13
Mileage_mid	46.45	4.208411e+13
Condition	33.00	2.359823e+13
n_extras_total	32.31	5.130566e+13
Number.of.Doors	20.11	3.291935e+12

Conclusión de regresión

El *Random Forest* es el modelo de mejor desempeño en todas las métricas de error, con una reducción sustancial del NMSE respecto al *baseline* lineal. Los principales determinantes del precio son consistentes entre los tres modelos: **antigüedad** (Age), **tipo de transmisión** (Gearbox), **kilometraje** (Mileage_mid), **potencia fiscal** y **estado del vehículo** (Condition). La no linealidad detectada por los gráficos ALE — especialmente la fuerte prima de los vehículos recientes— explica por qué los modelos basados en árboles superan a la regresión lineal. Esta última, pese a su menor precisión predictiva, retiene valor como herramienta interpretativa para cuantificar efectos marginales directamente legibles, y ofrece al comprador una estimación de precio ajustada, transparente y explicable.

Conclusiones

Este trabajo ha aplicado un *pipeline* completo de minería de datos al dataset MUCars-2024, abordando los dos objetivos planteados en la introducción.

Sobre la predicción del precio (Price): el modelo *Random Forest* se confirma como la mejor alternativa predictiva, mejorando claramente al árbol CART y al modelo lineal en todas las métricas de error evaluadas sobre el conjunto de test. La antigüedad del vehículo es el factor más determinante del precio, seguido del tipo de cambio, el kilometraje y la potencia fiscal. Los gráficos ALE revelan una depreciación no lineal concentrada en los primeros años, lo que explica la ventaja de los modelos basados en árboles. Desde el punto de vista práctico, el modelo desarrollado permite a cualquier comprador obtener una estimación objetiva del valor de mercado de un vehículo y compararlo con el precio publicado en el anuncio, reduciendo la incertidumbre en la toma de decisiones de compra.

Sobre la clasificación del primer propietario (First.Owner): los cinco modelos evaluados presentan métricas similares entre sí, lo que refleja el limitado poder discriminante de las variables disponibles en el anuncio sobre el historial de propiedad. Se selecciona la regresión logística como modelo definitivo por su interpretabilidad: los odds ratios confirman que los vehículos más recientes, con menos kilometraje y en mejor estado tienen mayor probabilidad de ser primer propietario, lo cual es coherente con la lógica del mercado.

Sobre el análisis no supervisado: el PCA sobre las variables numéricas revela dos ejes principales de variabilidad —el eje de depreciación (Age, Mileage_mid vs. Price) y el eje de equipamiento (n_extras)— que explican conjuntamente en torno al 60 % de la varianza. Esta estructura subyacente es consistente con los resultados de los modelos supervisados.

En conjunto, el trabajo ha permitido aplicar y comparar técnicas vistas en la asignatura —imputación KNN, PCA, regresión lineal con selección de variables, árboles de decisión, *Random Forest*, SVM, Naive Bayes, ALE y LIME— sobre un dataset real y de tamaño relevante, demostrando que la minería de datos aporta valor concreto para entender la dinámica de precios en un mercado complejo como el de los coches de segunda mano en Marruecos.

Anexos

Anexo I. Librerías y ficheros

Anexo I. Paquetes de R utilizados en el análisis.

Paquete	Uso
readxl	Lectura de ficheros Excel
writexl	Escritura de ficheros Excel
VIM	Imputacion KNN
FactoMineR	PCA
factoextra	Visualizacion PCA
caret	Particion, CV y entrenamiento de modelos
rpart	Arboles CART
rpart.plot	Visualizacion de arboles
DMwR2	Regla 1-SE (rpartXse)
randomForest	Random Forest
iml	ALE y LIME (interpretabilidad)
auditor	Curva REC
pROC	Curvas ROC y AUC
kernlab	SVM lineal
klaR	Naive Bayes
ggplot2	Graficos

Anexo I (cont.). Relacion de ficheros del proyecto.


Fichero	Descripcion
01_morocco_cars_original.xlsx	Dataset original descargado de Mendeley Data (Tabarnoust et al., 2025)
02_morocco_cars_limpios.xlsx	Dataset tras limpieza y preprocesamiento (generado por el Rmd)
datos_imputados_knn.xlsx	Dataset imputado con KNN (generado por el Rmd; input para modelos supervisados y PCA)
trabajo_final_v2.Rmd	Documento principal de analisis (este fichero)
refs.bib	Fichero de bibliografia BibTeX
graficas/	Carpeta con todas las graficas generadas durante el analisis

Anexo II. Descripción del dataset y análisis exploratorio

Tabla A1. Variables del dataset MUCars-2024, tipo y rol en el analisis.


Variable	Tipo	Rol
Brand	Nominal	Excluida (fusionada en BrandModel)
Model	Nominal	Excluida (fusionada en BrandModel)
Year → Age	Discreta	Predictor
Condition	Ordinal	Predictor / suplementaria PCA
Mileage → Mileage_mid	Numerica continua	Predictor
Gearbox	Nominal	Predictor
Fuel	Nominal	Predictor
Fiscal.Power → Fiscal_Power_num	Discreta	Predictor
Number.of.Doors	Discreta	Predictor (factor)
Origin	Nominal	Excluida de modelos supervisados
First.Owner	Binaria	Objetivo clasificacion
Location	Nominal	Excluida (alta cardinalidad)
Sector	Nominal	Excluida (alta cardinalidad)
Equipment → n_extras_*	Discreta (contadores)	Predictor (n_extras_total)
Price	Continua	Objetivo regresion

Variables numéricas imputadas (comparación antes/después)




Variables categ3ricas imputadas (comparaci3n antes/despu3s)


Distribucion de Condition (Top 10)




Distribucion de Number.of.Doors (Top 10)





Distribucion de Origin (Top 10)








Distribucion de Sector (Top 10)



Variables no imputadas







Anexo III. Detalles de modelos de clasificación

Tabla A2. Odds ratios de la regresion logistica.

	Odds Ratio
(Intercept)	3.0366
Age	0.8970
Mileage_mid	1.0000
Fiscal_Power_num	1.0329
Number.of.Doors5	0.5893
n_extras_total	1.0087
GearboxManual	0.7809
FuelElectric	0.8160

	Odds Ratio
FuelHybrid	1.4656
FuelLPG	0.6798
FuelPetrol	0.8521
ConditionExcellent	2.1632
ConditionFair	1.3683
ConditionFor Parts	1.7221
ConditionGood	1.0958
ConditionNew	3.7239
ConditionVery Good	1.5067

Tabla A3. Matriz de confusion — Regresion logistica.

	No	Yes
No	7042	2130
Yes	1842	3829

Tabla A4. Metricas — Regresion logistica.

Metrica	Valor
Accuracy	0.7324
Precision	0.6752
Recall	0.6426
F1	0.6585
AUC	0.7884

Arbol CART — First.Owner




Tabla A5. Matriz de confusion — Arbol CART.

	No	Yes
No	7452	2453
Yes	1432	3506

Tabla A6. Metricas — Arbol CART.

Metrica	Valor
Accuracy	0.7383
Precision	0.7100
Recall	0.5884
F1	0.6435
AUC	0.7464




Tabla A7. Matriz de confusion — Random Forest.

	No	Yes
No	7377	2170
Yes	1507	3789

Tabla A8. Metricas — Random Forest.

Metrica	Valor
Accuracy	0.7523
Precision	0.7154
Recall	0.6358
F1	0.6733
AUC	0.8069

Tabla A9. Matriz de confusion — SVM lineal.

	No	Yes
No	7031	2103
Yes	1853	3856

Tabla A10. Metricas — SVM lineal.

Metrica	Valor
Accuracy	0.7335
Precision	0.6754
Recall	0.6471
F1	0.6609
AUC	0.7882

Tabla A11. Matriz de confusion — Naive Bayes.


	No	Yes
No	6857	1997
Yes	2027	3962

Tabla A12. Metricas — Naive Bayes.

Metrica	Valor
Accuracy	0.7289
Precision	0.6615
Recall	0.6649
F1	0.6632
AUC	0.7864

Anexo IV. Diagnósticos, árbol CART y ALE/LIME


Diagnóstico de residuos — LM sobre log(Price)



El QQ-plot muestra un comportamiento próximo a la distribución normal en la región central. Las desviaciones en las colas corresponden a vehículos con precios muy alejados del rango habitual, inevitables en datos de anuncios reales. La transformación logarítmica ha corregido con éxito la asimetría severa de los precios en escala original.


Árbol CART podado — Price

Arbol CART podado (regla 1-SE) — Price




ALE y LIME — interpretabilidad del Random Forest

Efectos ALE (Accumulated Local Effects): a diferencia de los gráficos de dependencia parcial (PDP), los ALE no sufren el sesgo de correlación entre predictores. El eje vertical representa la desviación media del precio predicho respecto al precio medio, condicionada a los datos observados.




El gráfico ALE de Age revela una depreciación no lineal y fuertemente decreciente: los vehículos de menos de 5 años acumulan una prima muy significativa sobre el precio medio. Esta prima se desvanece de forma pronunciada hasta los 15 años y luego se estabiliza, lo que justifica la superioridad del *Random Forest* sobre la regresión lineal.



El ALE de Mileage_mid muestra una penalización pronunciada hasta los 200.000 km que luego se estabiliza. Su impacto total es considerablemente menor que el de la antigüedad.

LIME (Local Interpretable Model-agnostic Explanations): LIME entrena localmente un modelo lineal simple alrededor de una observación de interés para explicar *por qué el modelo asignó ese precio específico*.



Referencias

Anthropic. 2025. *Claude Code: An Agentic Coding Tool*. Anthropic, PBC.
<https://docs.anthropic.com/en/docs/claude-code>.

Breiman, Leo. 2001. «Random Forests». *Machine Learning* 45 (1): 5-32.
<https://doi.org/10.1023/A:1010933404324>.

Breiman, Leo, Jerome Friedman, Richard Olshen, y Charles Stone. 1984.
Classification and Regression Trees. Wadsworth.

Debón Aucejo, Ana. 2025. *Introducción a la Minería de Datos. Apuntes de la asignatura*. Master Universitario Ingeniería del Análisis de Datos, Mejora de Procesos y Toma de Decisión, curso 2025-2026. Universitat Politècnica de València.

Gosiewska, Alicja, y Przemyslaw Biecek. 2019. «auditor: an R Package for Model-Agnostic Visual Validation and Diagnostics». *The R Journal* 11 (2): 85-98.
<https://doi.org/10.32614/RJ-2019-036>.

Kassambara, Alboukadel, y Fabian Mundt. 2020. *factoextra: Extract and Visualize the Results of Multivariate Data Analyses*. <https://CRAN.R-project.org/package=factoextra>.

Kowarik, Alexander, y Matthias Templ. 2016. «Imputation with the R Package VIM». *Journal of Statistical Software* 74 (7): 1-16. <https://doi.org/10.18637/jss.v074.i07>.

Kuhn, Max. 2008. «Building Predictive Models in R Using the caret Package». *Journal of Statistical Software* 28 (5): 1-26. <https://doi.org/10.18637/jss.v028.i05>.

Lê, Sébastien, Julie Josse, y François Husson. 2008. «FactoMineR: An R Package for Multivariate Analysis». *Journal of Statistical Software* 25 (1): 1-18. <https://doi.org/10.18637/jss.v025.i01>.

Molnar, Christoph, Bernd Bischl, y Giuseppe Casalicchio. 2018. *iml: Interpretable Machine Learning*. <https://CRAN.R-project.org/package=iml>.

R Core Team. 2024. *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing. <https://www.R-project.org/>.

Tabarnoust, Abdellah, Ghita Mghari, y Yassine Zaz. 2025. *MUCars-2024: A Comprehensive Dataset of Used Cars Listed on Moroccan Online Platforms*. Mendeley Data. <https://doi.org/10.17632/5m3npjv5vf.1>.

Wickham, Hadley. 2016. *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag New York. <https://ggplot2.tidyverse.org>.