Predicción del turismo internacional en España ante una ruptura estructural: enfoques deterministas y ARIMA

Asignatura: Técnicas de Previsión (2025/26)

Oier Uribarren Arteaga
Universitat Politècnica de València

Marc Broch Callergues
Universitat Politècnica de València

Jose Ramón Mena Pérez
Universitat Politècnica de València

Resumen

En este trabajo se emplea la serie temporal mensual del número total de turistas internacionales que visitan España, según los datos FRONTUR del Instituto Nacional de Estadística (INE), desde octubre de 2015 hasta octubre de 2025. La serie presenta tendencia creciente, estacionalidad anual marcada y una ruptura estructural debido a la pandemia de COVID-19. Se analizan modelos deterministas (medias móviles, suavizado exponencial simple, Holt y Holt-Winters) y se ajusta un modelo ARIMA siguiendo la metodología Box-Jenkins, comparando el rendimiento en la serie completa y en el tramo post-COVID.

1. Introducción y objetivos

En el siguiente trabajo se empleará la serie temporal correspondiente al número total de turistas internacionales que visitan España cada mes, según los datos publicados por la Estadística de Movimientos Turísticos en Fronteras (FRONTUR) del Instituto Nacional de Estadística (INE).

El periodo analizado va desde octubre de 2015 hasta octubre de 2025, y los datos se han tomado de forma mensual, por lo que se ha acumulado más de 120 observaciones. Este gran volumen de observaciones permite que el uso de herramientas estadísticas sea sólido, tanto para el propio análisis de la serie, como para la realización de predicciones.

La variable recogida es el número absoluto de turistas internacionales, medido en personas, que han accedido al territorio nacional en un determinado mes. Esta variable resume la actividad turística global del país, independientemente del país de origen, de la vía de acceso o del motivo del viaje. Por tanto, representa la evolución general del turismo extranjero en España.

1.1 Datos de la serie

Un ejemplo de los datos que contiene la serie es la llegada de turistas internacionales durante el primer año de registro:

Año y mes	Número de turistas
2015M10	6.432.341
2015M11	3.754.802
2015M12	3.512.914
2016M01	3.526.537
2016M02	3.678.726
2016M03	4.627.206

Cuadro 1: Ejemplo de datos (primeros meses disponibles de la serie).

Si representamos la serie temporal completa, obtenemos:

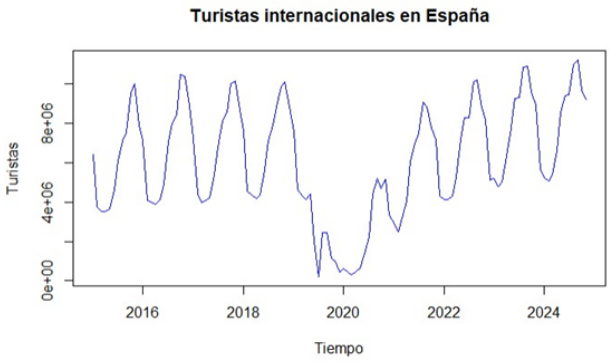

Figura 1: Turistas internacionales en España (serie mensual completa).

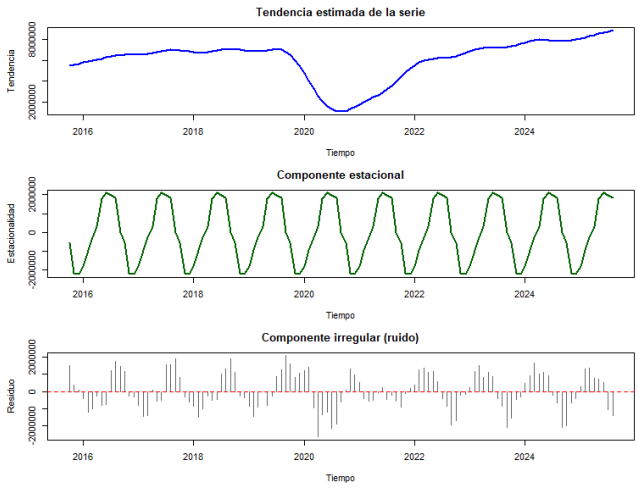

Figura 2: Descomposición de la llegada de turistas: datos, componente estacional, tendencia y residuo.

Al realizar un análisis visual, la serie revela tres etapas claramente diferenciadas: **(i) etapa pre-pandemia (2015–2019)**, donde hay un crecimiento sostenido, la tendencia es claramente ascendente cada año, y hay una

clara estacionalidad con picos en verano y mínimos en invierno; **(ii) etapa COVID-19 (2020–2021)**, donde la llegada de turistas se desploma por restricciones de movilidad, desaparecen prácticamente los patrones, no hay estacionalidad apreciable y la variabilidad se reduce mucho; y **(iii) etapa de recuperación y normalización (2022–2025)**, donde el turismo vuelve a su comportamiento habitual, se recupera la estacionalidad y la tendencia vuelve a ser creciente, incluso superando niveles pre-pandemia.

Por todo esto, analizar esta serie temporal es muy útil, porque incluye un shock externo muy fuerte como la pandemia, lo que permite comprobar cómo reaccionan distintos modelos cuando ocurre algo totalmente inesperado.

1.2 Tendencia

La tendencia de la serie muestra con claridad las tres etapas descritas: crecimiento sostenido hasta 2019, caída brusca en 2020 (punto más bajo) y recuperación progresiva desde 2021–2022 con una tendencia estable y ascendente en la fase final.

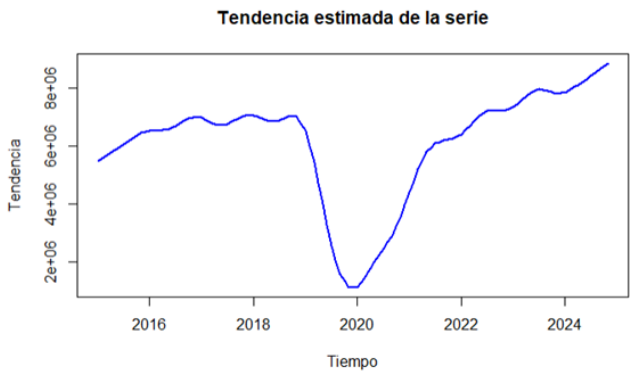

Figura 3: Tendencia estimada de la serie.

1.3 Varianza

La varianza móvil (12 meses) permite observar cómo cambia la variabilidad. Entre 2015 y 2019 se mantiene relativamente estable. En 2020 aparece un pico extremadamente alto y una caída abrupta (efecto COVID). Posteriormente, al paralizarse el turismo, la varianza cae a mínimos. A partir de 2021–2022 aumenta progresivamente y en 2024 se estabiliza en valores similares a los previos.

En conclusión, la varianza no es constante, por lo que resulta necesario aplicar transformaciones como el logaritmo o Box-Cox en la serie completa.

Año	Mínimo	Máximo	Rango
2016	3 526 537	10 027 471	6 500 934
2017	3 905 736	10 493 438	6 587 702
2018	4 106 601	10 175 761	6 069 160
2019	4 195 641	10 118 366	5 922 725
2020	204 272	4 427 344	4 223 072
2021	284 974	5 196 520	4 911 546
2022	2 501 443	9 091 390	6 589 947
2023	4 134 995	10 186 163	6 051 168
2024	4 775 549	10 929 584	6 154 035
2025	5 065 094	11 251 632	6 186 538

Cuadro 2: Mínimos, máximos y rango anual (2016–2025).

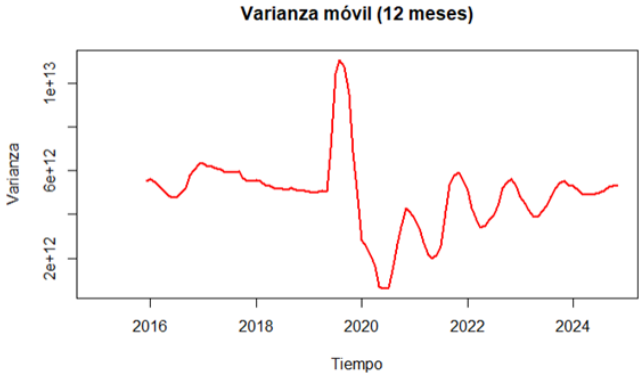

Figura 4: Varianza móvil (12 meses).

1.4 Estacionalidad

La componente estacional muestra un patrón anual fuerte y estable: máximos en verano y mínimos en invierno. Lo interesante es que el patrón estacional se mantiene incluso durante la pandemia, aunque quede "oculto" en los datos observados.

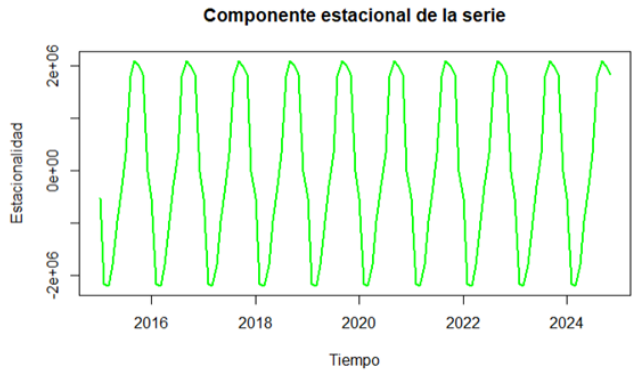

Figura 5: Componente estacional de la serie.

1.5 Esquema de la serie

Si obtenemos el máximo y mínimo de turistas en cada año, podemos calcular el rango y con ello aproximar si la estacionalidad es aditiva o multiplicativa.

Dado que en 2015 la serie solo incluye observaciones desde octubre, no se considera para decidir el esquema. En la serie completa, debido a la COVID-19, la estructura parece generalmente multiplicativa. Sin embargo, en el periodo post-COVID los rangos se mantienen relativamente estables ($\approx$ 6–6.6 millones), sugiriendo un comportamiento más cercano al esquema aditivo. Esto se tendrá en cuenta: en la serie completa se aplicará transformación logarítmica para estabilizar varianza.

2. Modelos deterministas

2.1 Pre-selección de modelos válidos

Antes de aplicar modelos deterministas, es necesario analizar qué métodos son adecuados para una serie con tendencia creciente, estacionalidad anual muy marcada y varianza no constante. Además, se analizarán tanto la serie completa (con COVID) como el periodo post-COVID (2022–2025) para comparar el impacto del shock y más adelante veremos que este último período será el más adecuado para realizar nuestras predicciones.

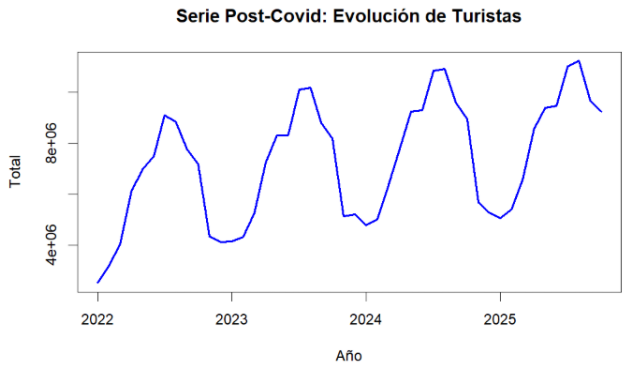

Figura 6: Serie mensual post-COVID (compactada) y estructura general.

Modelos NO adecuados. Las medias móviles (MM) suavizan y ayudan a ver la tendencia, pero no captan estacionalidad. El suavizado exponencial simple (SES) solo es recomendable cuando no hay tendencia ni estacionalidad.

Modelos parcialmente adecuados. Holt (doble suavizado) captura tendencia pero no estacionalidad.

Modelos plenamente adecuados. Holt-Winters (triple suavizado) incluye nivel, tendencia y estacionalidad (constantes α, β, γ) y es el candidato principal.

2.2 Análisis de los modelos

2.2.1. Medias móviles

El cálculo de las medias móviles unilaterales se basa en la siguiente fórmula:

$$MM(k)_t = \frac{Z_{t-k} + Z_{t-k+1} + \cdots + Z_{t-1}}{k} \qquad (1)$$

Se aplican distintas ventanas: MM(3) suaviza poco; MM(6) suaviza más; MM(12) elimina prácticamente la estacionalidad y permite visualizar claramente la tendencia, sobre todo en el periodo previo al COVID y durante la recuperación posterior.

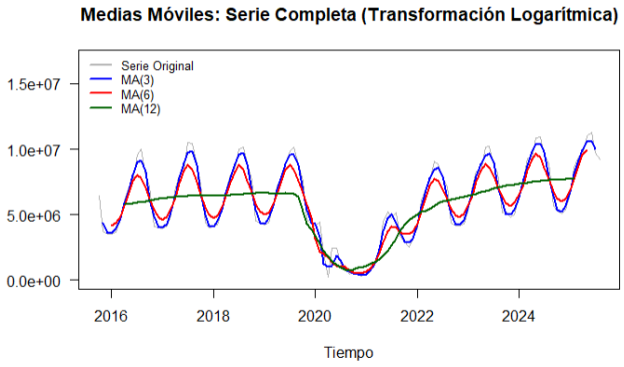

(a) Medias móviles: serie completa (transformación logarítmica).

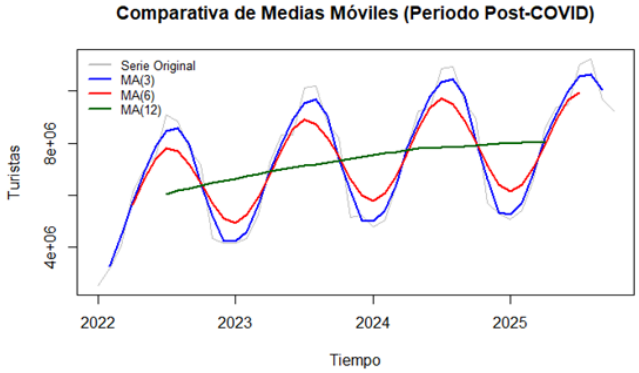

(b) Comparativa de medias móviles (periodo post-COVID).

Figura 7: Efecto del tamaño de ventana en el suavizado.

2.2.2. Suavizado exponencial simple (SES)

El SES aplica un filtro que da más peso a observaciones recientes, pero no modela tendencia ni estacionalidad:

$$F_{t+1} = \alpha Z_t + (1-\alpha)F_t, \quad 0 < \alpha < 1 \qquad (2)$$

Aunque puede seguir el movimiento general, no anticipa picos de verano ni mínimos de invierno, por lo que no genera predicciones realistas en esta serie.

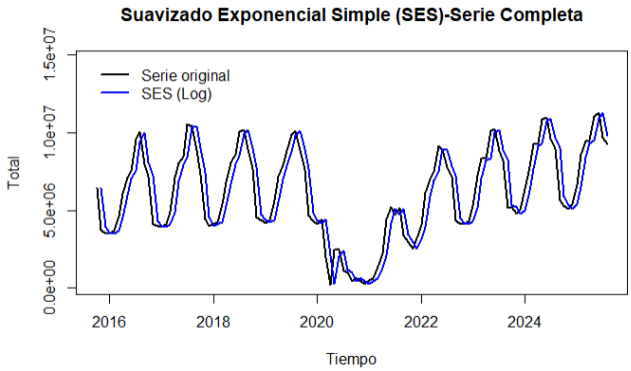

Figura 8: Suavizado exponencial simple (SES) sobre la serie.

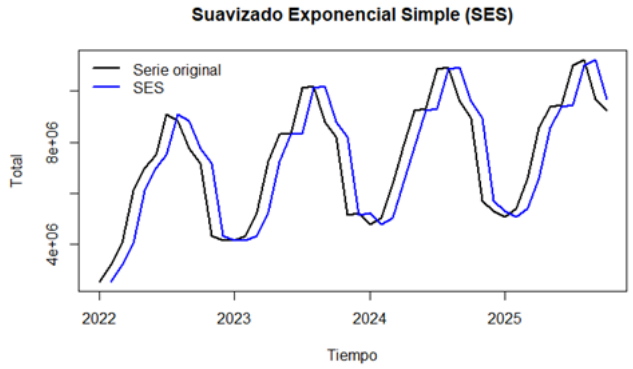

Figura 9: Suavizado exponencial simple (SES) sobre la serie.

2.2.3. Modelo de Holt (Suavizado exponencial doble)

Holt incorpora una constante para nivel (α) y otra para tendencia (β):

$$S_t = \alpha Z_t + (1-\alpha)(S_{t-1} + b_{t-1}) \tag{3}$$

$$b_t = \beta(S_t - S_{t-1}) + (1-\beta)b_{t-1} \tag{4}$$

$$F_{t+m} = S_t + mb_t \tag{5}$$

En la serie completa el shock COVID distorsiona la estimación de tendencia; en el tramo post-COVID el ajuste mejora, pero sigue sin capturar estacionalidad.

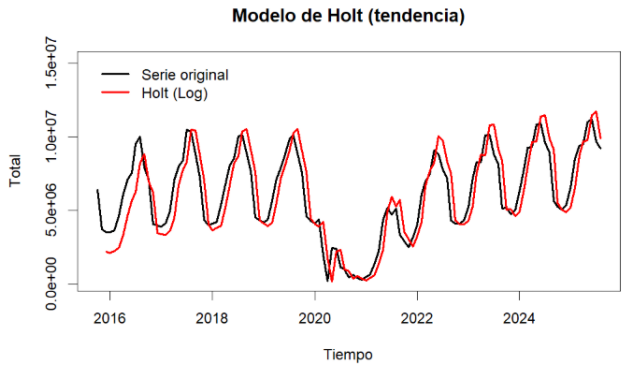

Figura 10: Modelo de Holt (tendencia): serie completa.

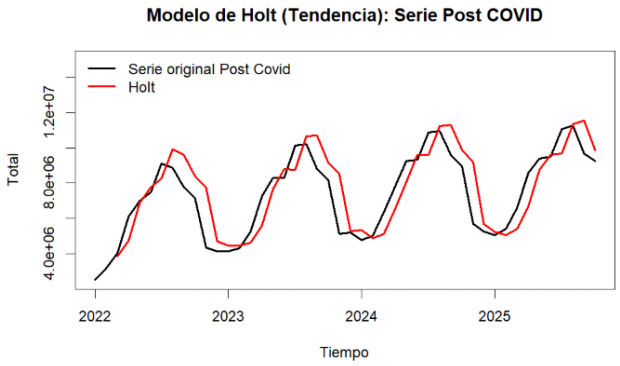

Figura 11: Modelo de Holt (tendencia): serie completa.

2.2.4. Modelo de Holt-Winters (Suavizado exponencial triple)

Holt-Winters incluye estacionalidad y reproduce picos estivales y mínimos invernales. En la serie completa, el ajuste se ve condicionado por la caída extrema de 2020–2021. En el periodo post-COVID, el modelo captura con mayor precisión tendencia y estacionalidad, con bandas de confianza más estrechas.

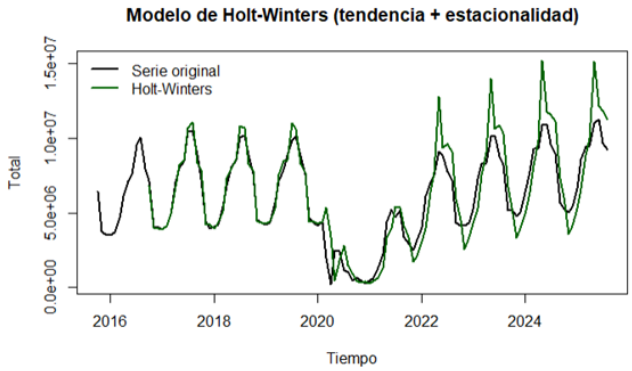

Figura 12: Modelo de Holt-Winters (tendencia + estacionalidad).

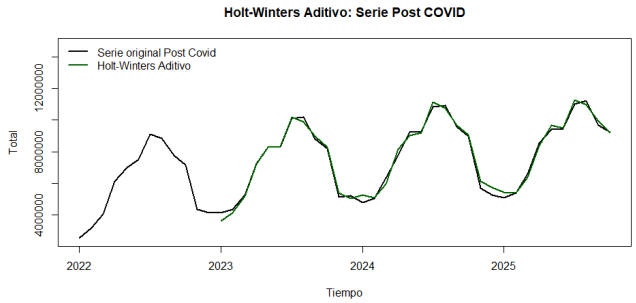

Figura 13: Modelo de Holt-Winters (tendencia + estacionalidad).

2.3 Comparación entre modelos deterministas

Serie	Modelo	MAE	RMSE	MAPE
Completa	SES	1 018 309.9	1 316 878.0	30.83
Completa	Holt	1 025 669.0	1 329 627.0	29.01
Completa	Holt-Winters	915 716.4	1 310 016.0	33.62
Post-COVID	SES	936 174.5	1 260 102.8	12.78
Post-COVID	Holt	971 104.2	1 282 963.4	13.32
Post-COVID	Holt-Winters	210 660.9	257 702.8	3.21

Cuadro 3: Comparación de precisión: MAE, RMSE y MAPE.

La tabla muestra que en la serie completa los errores son elevados por la ruptura COVID. En post-COVID, los errores se reducen notablemente y Holt-Winters aditivo es claramente superior, coherente con una estacionalidad de amplitud aproximadamente constante.

3. Modelos ARIMA

Además de los modelos deterministas analizados en el apartado anterior, vamos a ajustar un modelo tipo ARIMA, que permita capturar de forma explícita la dependencia temporal entre las observaciones y generar predicciones con intervalos de confianza.

Como se ha mencionado previamente, la serie presenta tendencia creciente, estacionalidad anual muy marcada y un comportamiento multiplicativo (especialmente al analizar el periodo completo con el shock COVID).

3.1 Metodología Box-Jenkins

La metodología Box–Jenkins consta de cuatro fases principales:

1. Obtención de una serie estacionaria (transformación y diferenciación).

2. Identificación de los órdenes del modelo $ARIMA(p,d,q)(P,D,Q)_s$ a partir de las funciones de autocorrelación (ACF) y autocorrelación parcial (PACF).

3. Estimación de los parámetros del modelo propuesto.

4. Validación del modelo mediante el análisis de los residuos.

Al observar que la serie presenta una tendencia clara, se aplica una diferencia regular ($d = 1$) para estabilizar la media. Dado que el comportamiento es multiplicativo y la varianza no es constante, se considera una transformación (logaritmo o Box–Cox) con el fin de estabilizar la varianza. Además, al detectarse estacionalidad anual, se aplica una diferencia estacional de longitud 12 ($D = 1$, periodo $s = 12$) para eliminar el patrón repetitivo asociado al ciclo anual.

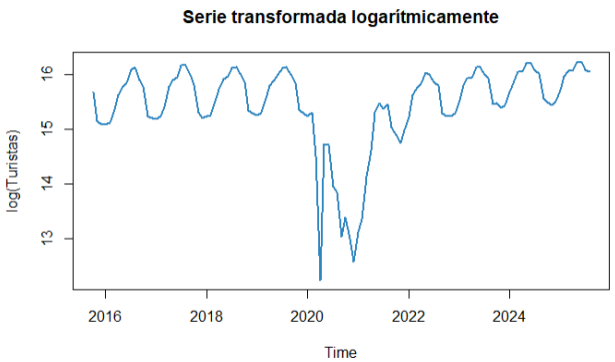

Figura 14: Serie transformada con Logaritmos

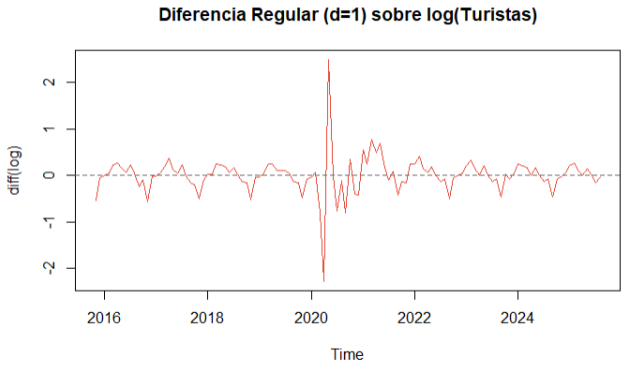

Figura 15: Diferencia Regular Serie Completa

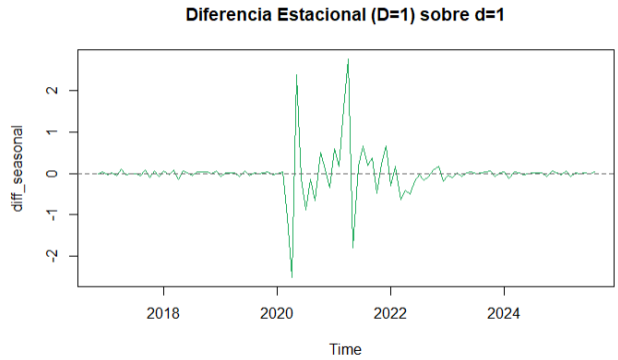

Figura 16: Diferencia Estacional Serie Completa

Tras aplicar la transformación (log/Box–Cox), la diferencia regular de primer orden y la diferencia estacional de periodo 12, se elimina la varianza no constante, la tendencia y el patrón estacional anual. Sin embargo, el periodo correspondiente a la pandemia (2020–2021) introduce una alteración muy marcada que rompe el comportamiento habitual y dificulta asumir estacionariedad en todo el intervalo temporal.

3.2 Elección del tramo post-COVID

Aunque se podría eliminar el periodo de la pandemia y unir los datos de antes y después del COVID, esta opción no es la más adecuada en este caso. La pandemia no solo provocó una caída puntual en los datos, sino que también cambió la forma de pensar y los hábitos de las personas, especialmente en lo relacionado con los viajes y el turismo. Como resultado, aunque el periodo post-COVID vuelve a mostrar un comportamiento estable, no es exactamente igual al periodo pre-COVID, ya que existen pequeñas diferencias en los niveles y en los patrones de comportamiento.

Por este motivo, juntar ambos periodos podría mezclar dinámicas distintas, dificultar el análisis y empeorar el ajuste. En conclusión, se considera más apropiado trabajar únicamente con la serie post-COVID, ya que refleja mejor el comportamiento actual y permite un análisis más claro y coherente.

Por este motivo, se decide continuar el análisis utilizando únicamente la serie post-COVID, a partir de 2022, donde el comportamiento vuelve a ser más estable y homogéneo.

En este tramo, la serie presenta una dinámica más regular, lo que facilita la aplicación de las transformaciones necesarias para alcanzar la estacionariedad, interpretar correctamente los gráficos ACF y PACF y proceder con la identificación y el ajuste de modelos ARIMA siguiendo Box–Jenkins.

Teniendo en cuenta que la serie post-COVID es bastante estable en varianza (comportamiento más cercano al esquema aditivo), se aplica la diferencia regular de primer orden y la diferencia estacional de periodo 12. Tras estas transformaciones, se puede considerar que la serie resultante es estacionaria.

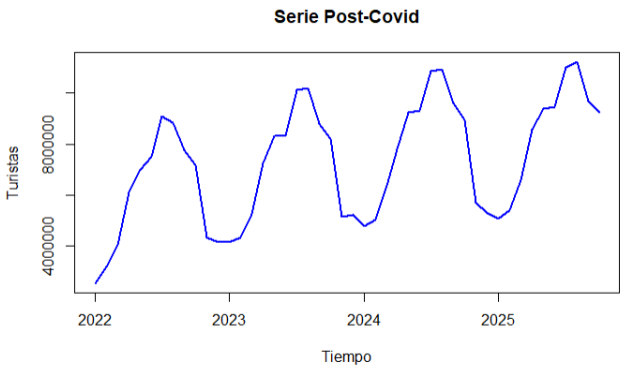

Figura 17: Serie Post Covid

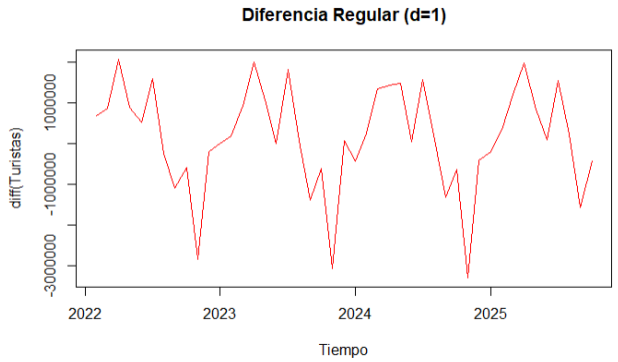

Figura 18: Diferencia Regular Serie Post Covid

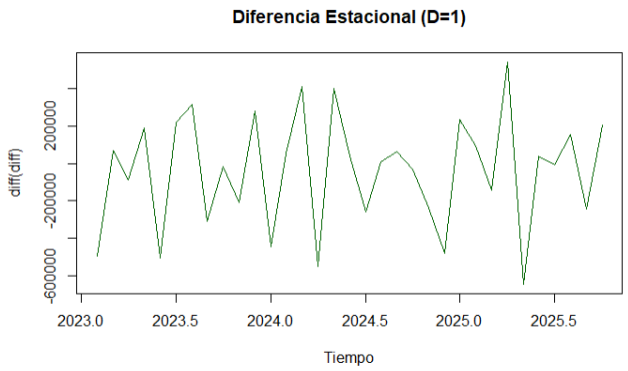

Figura 19: Diferencia Estacional Serie Post Covid

3.3 Identificación del modelo mediante ACF y PACF

Para identificar la estructura del modelo ARIMA más adecuada, se analizan las funciones de autocorrelación simple (ACF) y parcial (PACF) de la serie post-COVID transformada y diferenciada. Estos gráficos permiten detectar la presencia de componentes autorregresivos (AR) y de medias móviles (MA), así como comprobar si las transformaciones aplicadas han conseguido eliminar la tendencia y la estacionalidad.

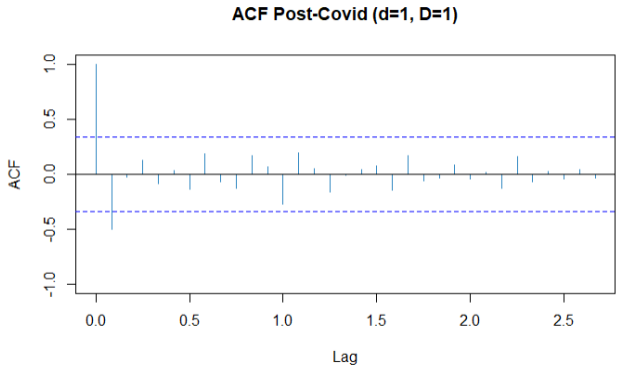

Figura 20: ACF de la serie post-COVID tras aplicar $d = 1$ y $D = 1$(periodo 12).

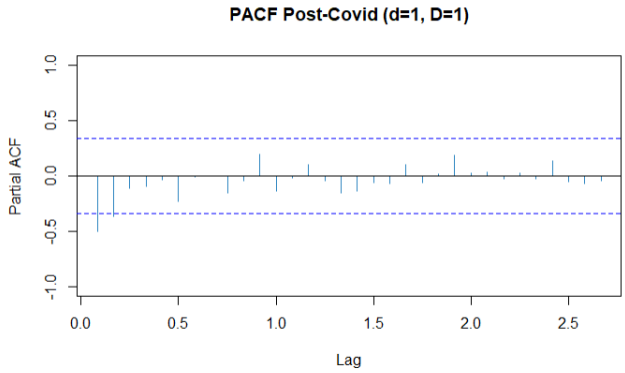

Figura 21: PACF de la serie post-COVID tras aplicar $d = 1$ y $D = 1$ (periodo 12).

Al observar los gráficos ACF y PACF, una vez aplicada la diferencia regular y la diferencia estacional, se aprecia un pico significativo en el primer retardo de la ACF con un corte brusco, mientras que el resto de retardos permanecen dentro de las bandas de confianza. En el caso de la PACF no aparece un patrón claro que indique la necesidad de incluir términos autorregresivos, ya que los picos son pequeños, caen lentamente y no muestran un corte definido.

Este comportamiento sugiere que, tras eliminar tendencia y estacionalidad, la dependencia temporal remanente es principalmente de corto plazo y puede recogerse con un término de medias móviles de primer orden. Por ello, el modelo que mejor se ajusta a la serie es:

$$ARIMA(0,1,1)(0,1,0)_{12}.$$

Antes de validar el modelo seleccionado manualmente, es conveniente comprobar si este modelo es realmente el más adecuado. Para ello, se utiliza la función `auto.arima()` (librería `forecast`), que aplica el procedimiento automatizado de Hyndman–Khandakar. Esta función puede aplicar transformación Box–Cox para estabilizar la varianza (si procede), elegir el nivel de diferenciación requerido y buscar el modelo ARIMA que mejor encaja comparando múltiples alternativas (habitualmente por AICc).

```
Series: turistas_post
ARIMA(0,1,1)(0,1,0)[12]
Box Cox transformation: lambda= 1.139516

Coefficients:
          ma1
      -0.6005
s.e.   0.1227

sigma^2 = 5.367e+12:  log likelihood = -530.18
AIC=1064.35   AICc=1064.75   BIC=1067.34
```

Figura 22: Salida de `auto.arima()` para la serie post-COVID (modelo propuesto).

Al aplicar el procedimiento automático `auto.arima()`, se obtiene de nuevo un $ARIMA(0,1,1)(0,1,0)_{12}$. En ambos casos se llega al mismo modelo, lo que indica que el análisis manual se ha realizado de forma correcta. Esta coincidencia refuerza la idea de que el modelo elegido recoge bien la dinámica de la serie y que no es necesario añadir más complejidad.

4. Validación del modelo escogido

Una vez ajustado el modelo ARIMA seleccionado, es necesario comprobar si los residuos cumplen las condiciones que exige la metodología Box–Jenkins. En particular, se debe verificar que los residuos presenten media nula, varianza constante, ausencia de autocorrelación y ausencia de periodicidades no explicadas.

4.1 Análisis de la significación de los parámetros

Para evaluar la validez del modelo ARIMA elegido, se analiza si los parámetros son significativos. Esta evaluación se realiza comparando cada coeficiente con su error estándar mediante el estadístico t, lo que permite determinar si cada término aporta información relevante al modelo.

En el modelo ajustado, el coeficiente $MA(1)$ toma un valor aproximado de $-0{,}6005$ con error estándar 0,1227, lo que produce un estadístico $t \approx -4{,}9$. Dado que $|t| > 2$, se rechaza la hipótesis de parámetro nulo y se concluye que el término $MA(1)$ es estadísticamente significativo.

4.2 Análisis de los residuos: ¿Ruido blanco?

4.2.1. Media nula

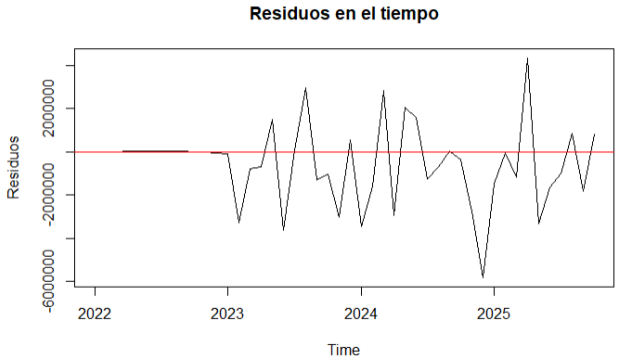

Figura 23: Residuos del modelo en el tiempo.

Al observar el gráfico de los residuos en el tiempo, se ve que fluctúan alrededor del valor cero y no se mantienen de forma continuada ni por encima ni por debajo. Aunque hay algunos valores puntuales más alejados, no aparece un patrón claro ni un desplazamiento constante en una dirección. Esto indica que el modelo no tiende a equivocarse siempre del mismo lado y que, en general, los residuos tienen media cercana a cero, por lo que este supuesto puede darse por cumplido.

4.2.2. Varianza constante

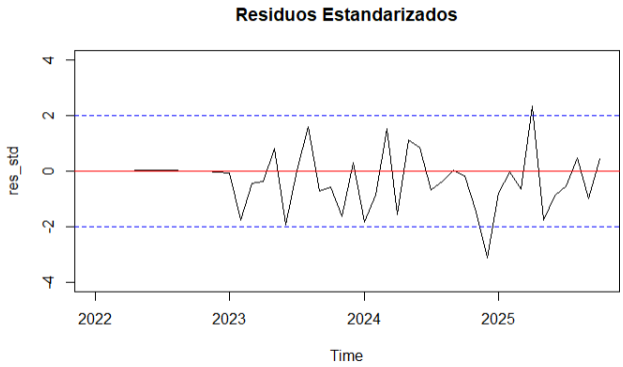

Figura 24: Residuos estandarizados.

Al analizar los residuos estandarizados se observa que su dispersión se mantiene bastante similar a lo largo del periodo. La mayoría de valores se encuentran dentro del rango habitual (aprox. ± 2) y no se aprecian tramos donde los residuos sean sistemáticamente más grandes o más pequeños. Aunque aparece algún valor puntual fuera de los límites, no se detectan cambios claros en la amplitud con el paso del tiempo. Por tanto, no hay indicios relevantes de heterocedasticidad y puede considerarse que la varianza de los residuos es aproximadamente constante.

4.2.3. ¿Están incorrelacionados?

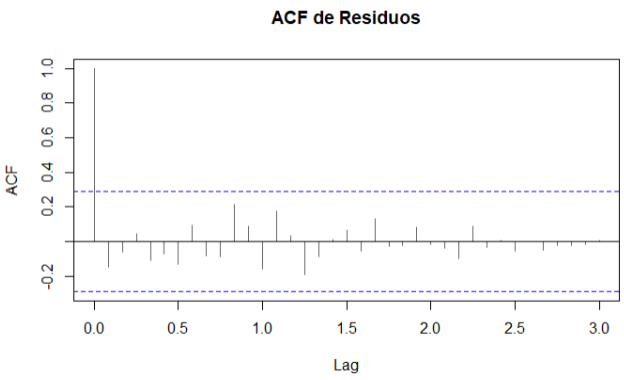

Figura 25: ACF de los residuos.

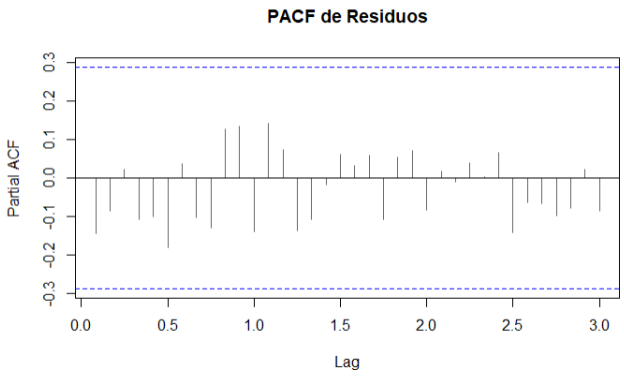

Figura 26: PACF de los residuos.

Para comprobar si los residuos del modelo ARIMA están incorrelacionados, se han analizado los gráficos ACF y PACF de los residuos. En ambos se observa que los coeficientes de autocorrelación permanecen dentro de las bandas de confianza, sin picos significativos ni patrones repetitivos. Esto sugiere que no queda dependencia temporal sin explicar y que los residuos pueden considerarse ruido blanco desde el punto de vista de autocorrelación.

4.2.4. ¿Siguen una distribución normal?

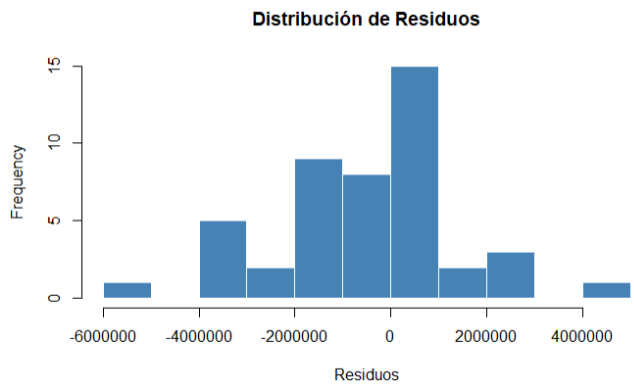

Figura 27: Histograma de los Residuos.

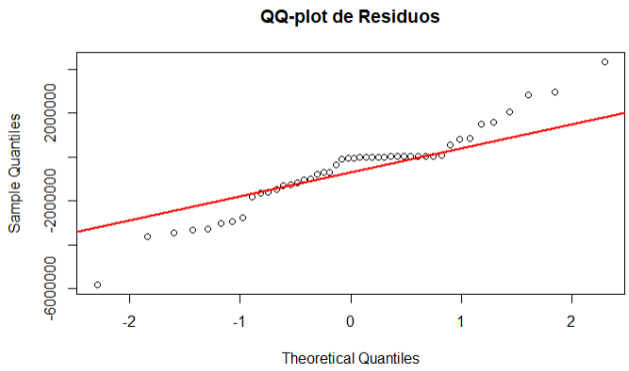

Figura 28: Papel Probabilístico Normal

Resultado del Test de Normalidad de Shapiro-Wilk

	Estadístico W	p-valor	Método
W	0.9533	0.0626	Shapiro-Wilk normality test

Figura 29: Shapiro-Wilk

El análisis de la normalidad de los residuos se realiza tanto de forma gráfica como mediante el contraste de Shapiro–Wilk. El histograma muestra una distribución centrada en cero y razonablemente simétrica, mientras que el QQ-plot presenta una alineación adecuada en la recta teórica, especialmente en la parte central, con ligeras desviaciones en los extremos.

El contraste Shapiro–Wilk no rechaza la hipótesis de normalidad (p-valor $\approx 0{,}0626$), por lo que, en conjunto, puede considerarse que los residuos siguen de forma aproximada una distribución normal.

4.2.5. Conclusión de validación

En conclusión, el análisis de validación del modelo seleccionado indica que su comportamiento es adecuado para describir y predecir la serie post-COVID. Los residuos presentan una media cercana a cero, una dispersión relativamente estable y no muestran autocorrelación significativa, por lo que pueden considerarse ruido blanco. En cuanto a la normalidad, tanto el análisis gráfico como el contraste de Shapiro–Wilk indican que los residuos pueden considerarse aproximadamente normales.

Estos resultados permiten concluir que el modelo cumple razonablemente bien los supuestos básicos de Box–Jenkins y puede considerarse un modelo adecuado y fiable para el análisis y la predicción de la serie temporal.

4.3 Comparación de modelos alternativos

A continuación, se presentan los valores de RMSE de los modelos deterministas y del modelo ARIMA ajustado (en el tramo post-COVID) para comparar la precisión de predicción.

Modelo	RMSE
SES	1 260 102.8
Holt	1 282 963.4
Holt-Winters	257 702.8
ARIMA(0,1,1)(0,1,0)[12]	215 119.6

Cuadro 4: Comparación de RMSE entre modelos (tramo post-COVID).

Los modelos deterministas más simples, como SES y Holt, presentan errores claramente más elevados, lo que es esperable al no incorporar adecuadamente la estacionalidad. El modelo Holt-Winters mejora notablemente los resultados al incorporar estacionalidad, reduciendo de forma importante el error de predicción.

Por su parte, el modelo $ARIMA(0,1,1)(0,1,0)_{12}$ obtiene el menor RMSE (aprox. 215 119,6), lo que indica que es el modelo que mejor reproduce el comportamiento de la serie post-COVID. Este resultado confirma que el ARIMA seleccionado consigue capturar tanto la dinámica temporal como las variaciones estacionales de forma más precisa que los modelos deterministas considerados. En conclusión, atendiendo al criterio RMSE y a la correcta validación de residuos, el modelo ARIMA se considera la opción más adecuada para el análisis y la predicción de la serie estudiada.

5. Explotación del modelo escogido

5.1 Ecuación explícita del modelo

Sea Y_t la serie original (turistas) y sea Z_t la serie transformada mediante Box–Cox con $\lambda = 1{,}139516$:

$$Z_t = \frac{Y_t^{\lambda} - 1}{\lambda}.$$

Se define la serie estacionaria mediante diferenciación regular y estacional:

$$W_t = (1-B)(1-B^{12})Z_t.$$

Desarrollando:

$$W_t = Z_t - Z_{t-1} - Z_{t-12} + Z_{t-13}.$$

El modelo ajustado es $ARIMA(0,1,1)(0,1,0)_{12}$, es decir, un MA(1) sobre W_t:

$$W_t = (1+\theta_1 B)a_t = a_t + \theta_1 a_{t-1}, \qquad \hat{\theta}_1 = -0{,}6005,$$

donde a_t es el residuo en el instante t.

5.2 Ecuaciones de predicción a 12 meses

Sea $T =$ octubre 2025 el último periodo observado. Para predicción:

$$\widehat{W}_{T+1|T} = \theta_1 a_T, \qquad \widehat{W}_{T+h|T} = 0 \ \text{ para } \ h \geq 2.$$

A partir de $W_t = Z_t - Z_{t-1} - Z_{t-12} + X_{t-13}$, se obtiene:

$$\widehat{Z}_{T+h|T} = \widehat{Z}_{T+h-1|T} + Z_{T+h-12} - Z_{T+h-13} + \widehat{W}_{T+h|T}.$$

En el presente caso:

$$a_T = a_{\text{Oct-2025}} = 796\,125, \qquad \theta_1 a_T = -478\,073{,}062\,5.$$

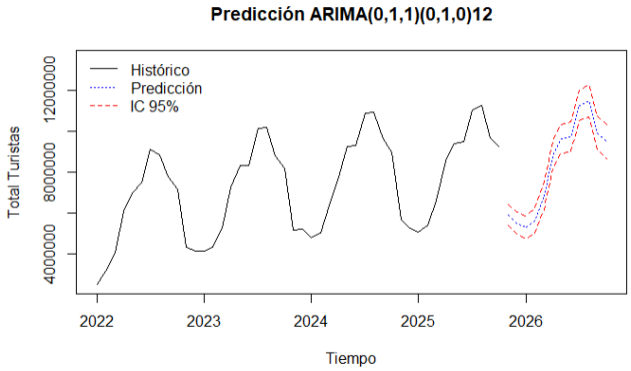

Figura 30: Predicción a 12 meses con el modelo ARIMA seleccionado.

5.2.1. Comprobación manual de las predicciones obtenidas en el ordenador

En esta sección se muestra el cálculo manual de las 12 predicciones (noviembre 2025–octubre 2026) en la escala transformada Z_t, utilizando el residuo final del ajuste $a_{\text{Oct-2025}}$ y la recurrencia derivada de la doble diferenciación, así como el valor real de la predicción.

5.2.2. Valores necesarios (escala transformada)

Se emplean los valores transformados (Box–Cox) observados en los 12 meses previos y el último mes disponible:

$$X_{\text{Oct-2024}} = 73\,392\,634{,}841, \quad X_{\text{Nov-2024}} = 43\,562\,684{,}112,$$

$$X_{\text{Dec-2024}} = 40\,027\,807{,}605, \quad X_{\text{Jan-2025}} = 38\,305\,779{,}386,$$

$$X_{\text{Feb-2025}} = 41\,181\,346{,}322, \quad X_{\text{Mar-2025}} = 51\,734\,370{,}715,$$

$$X_{\text{Apr-2025}} = 69\,729\,224{,}808, \quad X_{\text{May-2025}} = 77\,453\,180{,}494,$$

$$X_{\text{Jun-2025}} = 78\,211\,099{,}646, \quad X_{\text{Jul-2025}} = 92\,918\,927{,}700,$$

$$X_{\text{Aug-2025}} = 95\,115\,757{,}822, \quad X_{\text{Sep-2025}} = 80\,144\,525{,}363,$$

$$X_{\text{Oct-2025}} = 76\,039\,354{,}102.$$

Además:

$$a_{\text{Oct-2025}} = 796\,125, \qquad \theta_1 a_{\text{Oct-2025}} = -478\,073{,}062\,5.$$

5.2.3. Cálculo manual de los 12 pronósticos

(1) Noviembre 2025

$$\begin{aligned}\widehat{Z}_{\text{Nov-2025}} &= Z_{\text{Oct-2025}} + Z_{\text{Nov-2024}} - Z_{\text{Oct-2024}} + \theta_1 a_{\text{Oct-2025}} \\ &= 76\,039\,354{,}1 + 43\,562\,684{,}11 \\ &- 73\,392\,634{,}84 - 478\,073{,}062\,5 \\ &= 45\,731\,330{,}310.\end{aligned} \tag{6}$$

$$\widehat{Y}_{\text{Nov-2025}} \approx 5\,917\,193$$

(2) Diciembre 2025

$$\begin{aligned}\widehat{Z}_{\text{Dec-2025}} &= \widehat{Z}_{\text{Nov-2025}} + Z_{\text{Dec-2024}} - Z_{\text{Nov-2024}} \\ &= 45\,731\,330{,}310 + 40\,027\,807{,}605 - 43\,562\,684{,}112 \\ &= 42\,196\,453{,}804.\end{aligned} \tag{7}$$

$$\widehat{Y}_{\text{Dec-2025}} \approx 5\,513\,857$$

(3) Enero 2026

$$\begin{aligned}\widehat{Z}_{\text{Jan-2026}} &= \widehat{Z}_{\text{Dec-2025}} + Z_{\text{Jan-2025}} - Z_{\text{Dec-2024}} \\ &= 42\,196\,453{,}804 + 38\,305\,779{,}386 - 40\,027\,807{,}605 \\ &= 40\,474\,425{,}584.\end{aligned} \tag{8}$$

$$\widehat{Y}_{\text{Jan-2026}} \approx 5\,315\,887$$

(4) Febrero 2026

$$\begin{aligned}\widehat{Z}_{\text{Feb-2026}} &= \widehat{Z}_{\text{Jan-2026}} + Z_{\text{Feb-2025}} - Z_{\text{Jan-2025}} \\ &= 40\,474\,425{,}584 + 41\,181\,346{,}322 - 38\,305\,779{,}386 \\ &= 43\,349\,992{,}520.\end{aligned} \tag{9}$$

$$\widehat{Y}_{\text{Feb-2026}} \approx 5\,645\,917$$

(5) Marzo 2026

$$\begin{aligned}\widehat{Z}_{\text{Mar-2026}} &= \widehat{Z}_{\text{Feb-2026}} + Z_{\text{Mar-2025}} - Z_{\text{Feb-2025}} \\ &= 43\,349\,992{,}520 + 51\,734\,370{,}715 - 41\,181\,346{,}322 \\ &= 53\,903\,016{,}913.\end{aligned} \tag{10}$$

$$\widehat{Y}_{\text{Mar-2026}} \approx 6\,835\,547$$

(6) Abril 2026

$$\begin{aligned}\widehat{Z}_{\text{Apr-2026}} &= \widehat{Z}_{\text{Mar-2026}} + Z_{\text{Apr-2025}} - Z_{\text{Mar-2025}} \\ &= 53\,903\,016{,}913 + 69\,729\,224{,}808 - 51\,734\,370{,}715 \\ &= 71\,897\,871{,}006.\end{aligned} \tag{11}$$

$$\widehat{Y}_{\text{Apr-2026}} \approx 8\,801\,553$$

(7) Mayo 2026

$$\begin{aligned}\widehat{Z}_{\text{May-2026}} &= \widehat{Z}_{\text{Apr-2026}} + Z_{\text{May-2025}} - Z_{\text{Apr-2025}} \\ &= 71\,897\,871{,}006 + 77\,453\,180{,}494 - 69\,729\,224{,}808 \\ &= 79\,621\,826{,}692.\end{aligned} \tag{12}$$

$$\widehat{Y}_{\text{May-2026}} \approx 9\,626\,083$$

(8) Junio 2026

$$\begin{aligned}\widehat{Z}_{\text{Jun-2026}} &= \widehat{Z}_{\text{May-2026}} + Z_{\text{Jun-2025}} - Z_{\text{May-2025}} \\ &= 79\,621\,826{,}692 + 78\,211\,099{,}646 - 77\,453\,180{,}494 \\ &= 80\,379\,745{,}844.\end{aligned} \tag{13}$$

$$\widehat{Y}_{\text{Jun-2026}} \approx 9\,706\,448$$

(9) Julio 2026

$$\begin{aligned}\widehat{Z}_{\text{Jul-2026}} &= \widehat{Z}_{\text{Jun-2026}} + Z_{\text{Jul-2025}} - Z_{\text{Jun-2025}} \\ &= 80\,379\,745{,}844 + 92\,918\,927{,}700 - 78\,211\,099{,}646 \\ &= 95\,087\,573{,}898.\end{aligned} \tag{14}$$

$$\widehat{Y}_{\text{Jul-2026}} \approx 11\,248\,706$$

(10) Agosto 2026

$$\begin{aligned}\widehat{Z}_{\text{Aug-2026}} &= \widehat{Z}_{\text{Jul-2026}} + Z_{\text{Aug-2025}} - Z_{\text{Jul-2025}} \\ &= 95\,087\,573{,}898 + 95\,115\,757{,}822 - 92\,918\,927{,}700 \\ &= 97\,284\,404{,}020.\end{aligned} \tag{15}$$

$$\widehat{Y}_{\text{Aug-2026}} \approx 11\,476\,449$$

(11) Septiembre 2026

$$\begin{aligned}\widehat{Z}_{\text{Sep-2026}} &= \widehat{Z}_{\text{Aug-2026}} + Z_{\text{Sep-2025}} - Z_{\text{Aug-2025}} \\ &= 97\,284\,404{,}020 + 80\,144\,525{,}363 - 95\,115\,757{,}822 \\ &= 82\,313\,171{,}561.\end{aligned} \tag{16}$$

$$\widehat{Y}_{\text{Sep-2026}} \approx 9\,911\,039$$

(12) Octubre 2026

$$\begin{aligned}\widehat{Z}_{\text{Oct-2026}} &= \widehat{Z}_{\text{Sep-2026}} + Z_{\text{Oct-2025}} - Z_{\text{Sep-2025}} \\ &= 82\,313\,171{,}561 + 76\,039\,354{,}102 - 80\,144\,525{,}363 \\ &= 78\,208\,000{,}300.\end{aligned} \tag{17}$$

$$\widehat{Y}_{\text{Oct-2026}} \approx 9\,475\,918$$

Los valores obtenidos coinciden (salvo errores por redondeos) con los valores reportados por el software en la salida de predicción en escala transformada y reescalada originalmente.

Valores Predichos para los próximos 12 meses (Intervalo de Confianza 95%)

Mes/Año	Valor Predicho	Lím. Inf (95%)	Lím. Sup (95%)
nov. 2025	5917190	5398354	6429746
dic. 2025	5513853	4949004	6070727
ene. 2026	5315883	4709813	5912439
feb. 2026	5645913	5009665	6272288
mar. 2026	6835544	6184323	7478206
abr. 2026	8801550	8143991	9452318
may. 2026	9626080	8948694	10296874
jun. 2026	9706445	9002696	10403140
jul. 2026	11248703	10534242	11956883
ago. 2026	11476446	10739396	12206946
sep. 2026	9911036	9133696	10679952
oct. 2026	9475915	8669611	10272747

Figura 31: Predicción del Software utilizado.

6. Conclusiones

El análisis de la serie mensual de turistas internacionales en España muestra una estacionalidad anual marcada, una tendencia creciente en el largo plazo y una ruptura estructural severa durante 2020–2021 asociada a la pandemia. Esta ruptura modifica el nivel y la variabilidad, dificultando el ajuste de modelos globales para todo el periodo y elevando la incertidumbre predictiva.

En el bloque determinista, los modelos que no incorporan estacionalidad (medias móviles, SES y Holt) resultan insuficientes para reproducir los máximos estivales y mínimos invernales. Holt–Winters, al incorporar estacionalidad, mejora de forma sustancial el ajuste, especialmente en el tramo post-COVID. La comparación de errores en dicho tramo confirma una fuerte reducción de MAE, RMSE y MAPE al trabajar con un periodo homogéneo.

Para el enfoque estocástico, se aplicó la metodología Box–Jenkins sobre el tramo post-COVID, empleando transformación Box–Cox y diferenciaciones regular y estacional. El análisis ACF/PACF y la confirmación con `auto.arima()` condujeron a un modelo parsimonioso $ARIMA(0,1,1)(0,1,0)_{12}$, cuyos residuos presentan propiedades compatibles con ruido blanco. La comparación con modelos deterministas muestra que el ARIMA seleccionado obtiene el menor RMSE, sugiriendo mayor precisión predictiva en el escenario post-COVID.

En conjunto, el trabajo pone de manifiesto la relevancia de detectar y tratar rupturas estructurales, segmentar el periodo de modelización cuando el comportamiento cambia, y seleccionar modelos coherentes con los componentes principales de la serie para obtener predicciones robustas y defendibles.

7. Referencias bibliográficas

- Instituto Nacional de Estadística (INE). *Estadística de Movimientos Turísticos en Fronteras (FRONTUR)*. Serie mensual de turistas internacionales en España. INEbase.
- García Díaz, J. C. *Predicción en el dominio del tiempo. Análisis de series temporales para ingenieros.* Editorial Universitat Politècnica de València.
- Google. *Gemini* (asistente de IA). Herramienta utilizada como apoyo en redacción y revisión del trabajo.
- OpenAI. *ChatGPT* (modelo: *GPT-5.2 Thinking*). Herramienta utilizada como apoyo en redacción y revisión del trabajo.
- Apuntes de la asignatura *Técnicas de Previsión* (curso 2025/26). Máster en Ingeniería de Análisis de Datos, Mejora de Procesos y Toma de Decisiones, Universitat Politècnica de València (material docente).
- Apuntes y material de *Programación en R para el Análisis de Datos* del Máster en Ingeniería de Análisis de Datos, Mejora de Procesos y Toma de Decisiones, Universitat Politècnica de València (material docente).